

Disseny i implementació d'una arquitectura Business Intelligence End-to-End per a l'anàlisi i predicció del benestar laboral en el sector tecnològic.

The logo of the Universitat Oberta de Catalunya (UOC) is displayed in a large, bold, dark blue font. The letters 'UOC' are visible, with the 'C' partially cut off on the right side.

Celio Sánchez Bañuls

TFG - Business Intelligence – Aula 1

Tutor/a de TF

Xavier Martínez Fontes

**Professor/a responsable de
l'assignatura**

Atanasi Daradoumis Haralabus

06/2026

Universitat Oberta
de Catalunya



Aquesta obra està subjecta a una llicència de [Reconeixement-NoComercial-SenseObraDerivada 3.0 Espanya de Creative Commons](https://creativecommons.org/licenses/by-nc-nd/3.0/es/)

Fitxa del Treball Final

Títol del treball:	Disseny i implementació d'una arquitectura Business Intelligence End-to-End per a l'anàlisi i predicció del benestar laboral en el sector tecnològic.
Nom de l'autor/a:	Celio Sánchez Bañuls
Nom del Tutor/a de TF:	Xavier Martinez Fontes
Nom del/de la PRA:	Atanasi Daradoumis Haralabus
Data de lliurament:	06/2026
Titulació o programa:	TFG - Business Intelligence
Àrea del Treball Final:	Business Intelligence (05.650)
Idioma del treball:	Català
Paraules clau	Business Intelligence, Mental Health, Human Resources, ETL, Python, Data Warehouse.
Resum del Treball	
Aquest Treball Final de Grau (TFG) té com a objectiu principal el desenvolupament d'una solució d'Intel·ligència de Negoci (BI) i Analítica Predictiva per quantificar l'impacte de la salut mental en el rendiment i la retenció de talent dins del sector tecnològic. Per aconseguir-ho, s'integren dades clíniques reals procedents de les enquestes històriques de l'OSMI (<i>Open Sourcing Mental Illness</i>) amb variables organitzatives generades de forma sintètica (salari, hores extres i avaluació de rendiment). Fins a la present fase, s'ha realitzat un perfilat de dades (<i>Data Profiling</i>) per identificar problemes de qualitat i deriva d'esquema (<i>Schema Drift</i>). A més, s'ha dissenyat i validat un procés ETL programat en Python per a la neteja i enriquiment de les dades, definint l'arquitectura del <i>Data Warehouse</i> mitjançant un model dimensional en estrella. El resultat final del projecte dotarà els departaments de Recursos Humans d'un quadre de comandament interactiu (Power BI) per prendre decisions estratègiques basades en dades (<i>data-driven</i>) que afavoreixin el benestar corporatiu.	

Abstract

This Bachelor's Thesis aims to develop a Business Intelligence (BI) and Predictive Analytics solution to quantify the impact of mental health on performance and talent retention within the tech sector.

To achieve this, real clinical data from historical OSMI (*Open Sourcing Mental Illness*) surveys are integrated with synthetically generated organizational variables (salary, overtime, and performance evaluation). Up to the current phase, data profiling has been conducted to identify quality issues and schema drift. Furthermore, an ETL process programmed in Python has been designed and validated for data cleaning and enrichment, defining the Data Warehouse architecture through a dimensional star schema model.

The final outcome of the project will provide Human Resources departments with an interactive dashboard (Power BI) to make data-driven strategic decisions that promote corporate well-being.

Index

1.	Introducció	5
1.1.	Context i justificació del Treball	5
1.2.	Objectius del Treball	7
1.3.	Impacte en sostenibilitat, ètic-social i de diversitat	8
1.4.	Enfocament i mètode seguit	9
1.5.	Planificació del Treball	10
	Fase 1: Iniciació i Planificació (PAC 1) [23/02/2026 - 08/03/2026]	10
	Fase 2: Anàlisi i Disseny de l'Arquitectura (PAC 2) [09/03/2026 - 08/04/2026]	11
	Fase 3: Implementació, ML i Dashboard (PAC 3) [09/04/2026 - 10/05/2026]	11
	Fase 4: Tancament i Memòria Final (PAC 4) [11/05/2026 - 07/06/2026]	11
	Fase 5: Defensa del Projecte (PAC 5) [08/06/2026 - 23/06/2026]	11
1.6.	Breu sumari de productes obtinguts	12
1.7.	Breu descripció dels altres capítols de la memòria	12
1.8.	Declaració sobre l'ús d'intel·ligència artificial generativa	13
2.	Materials i mètodes	14
2.1.	Revisió de l'estat de l'art (Metodologia PRISMA)	14
2.2.	Metodologia triada, alternatives i presa de decisions	15
2.3.	Definició de KPIs i preguntes de negoci.	16
2.4.	Descàrrega OSMI i Data Profiling (Anàlisi Exploràtoria)	18
2.4.1.	Origen i Ingesta de Dades	18
2.4.2.	Procés de Data Profiling	18
2.5.	Disseny conceptual i desenvolupament del procés ETL	20
2.5.1.	Fase d'Extracció (Extract)	20
2.5.2.	Fase de Transformació i Neteja (Transform)	20
2.5.3.	Fase d'Enriquiment i Generació Sintètica (Mock Data)	21
2.5.4.	Fase de Càrrega (Load)	22
2.6.	Modelatge dimensional: Esquema en estrella.	22
2.6.1.	Taula de Fets: <i>Fets_Rendiment_Benestar</i>	22
2.6.2.	Taules de Dimensions	23
2.6.3.	Avantatges Tècnics del Disseny	23
2.7.	Descripció dels productes obtinguts	24

2.8.	Justificació de l'eina de visualització i explotació: Power BI	25
2.9.	Reflexions sobre l'arquitectura i la gestió de la incrementalitat.	26
2.10.	Justificació del modelatge de dades sintètiques i avaluació del seu impacte.	26
3.	Resultats	28
3.1.	Pipeline ETL i Dataset Consolidat	28
3.1.1.	Execució del procés d'Extracció (Extract)	28
3.1.2.	Resolució de l'Schema Drift (Transform)	28
3.1.3.	Enriquiment amb dades sintètiques (Mock Data)	29
3.1.4.	Fase de Càrrega (Load) i Arxiu Mestre	29
3.2.	Arquitectura de Programari i Desenvolupament d'Scripts (Python)	30
3.2.1.	Mòdul 1: 00_data_profiling.py (Anàlisi Exploratòria i Perfilat de Dades)	30
3.2.2.	Mòdul 2: 01_Crea_Database.py (Definició de l'Esquema i Configuració del Data Warehouse)	31
3.2.3.	Mòdul 3: 02_etl.py (El Motor d'Integració i Resolució de l'Schema Drift)	32
3.2.4.	Mòdul 4: 03_MachineLearning.py (Model Clínic i RRHH)	34
3.2.5.	Mòdul 5: 04_PoC_MachineLearning.py (Prova de Concepte)	34
3.3.	Data Warehouse a Neon PostgreSQL	34
3.4.	Model de Machine Learning (03_MachineLearning.py)	35
3.4.1.	Configuració i rendiment del model	35
3.4.2.	Anàlisi d'Importància de Variables (Feature Importance)	36
3.5.	Prova de Concepte (PoC) en Predictive HR Analytics	37
3.6.	Quadre de Comandament (Power BI)	38
3.6.1.	KPI's principals BI i cost de l'estrès	39
3.6.2.	Anàlisi Demogràfica, Geogràfica i Biaixos	40
3.7.	Resum i valoració dels objectius assolits	41
4.	Conclusions i treballs futurs	42
4.1.	Treballs futurs	43
5.	Glossari	44
6.	Bibliografia	47
7.	Annexos	49
7.1.	Diccionari de Dades i Mapeig Semàntic OSMI	49
7.1.1.	Anàlisi d'Importància de Variables (Feature Importance)	49
7.1.2.	Evolució de l'Schema Drift per Any d'Enquesta	50

7.1.3.	Diccionari de dades i Mapeig semàntic complet	51
7.1.4.	Coeficients d'Interferència per al Càlcul del KPI CPP	54
7.1.5.	Lògica de Negoci Addicional dels KPIs	55
7.1.6.	Nota sobre la Reproductibilitat del Procés ETL	55
7.2.	Codi DAX Principal	56
7.2.1.	Mètrica Base (Context de Filtre)	56
7.2.2.	Cost de Pèrdua de Productivitat (CPP) - Ús de funcions iteradores	57
7.2.3.	Risc de Fuga de Talent - Modificació del Context de Filtre	57
7.2.4.	Correlació d'Hores Extres (Risc Relatiu)	58
7.3.	Repositori	59

Llista de Figures

Figura 1. Taula amb els objectius secundaris del projecte	Pàg. 8
Figura 2. Diagrama de Gantt amb la planificació del projecte	Pàg. 11
Figura 3. Ecosistema de scripts Python del projecte	Pàg. 30
Figura 4. Resum exemple del OSMI_Report_Global.html	Pàg. 31
Figura 5. Classification Report - Model Random Forest (dades reals OSMI)	Pàg. 36
Figura 6. Top 10 variables predictores - Model Random Forest	Pàg. 37
Figura 7. Classification Report - Prova de Concepte (PoC)	Pàg. 37
Figura 8. Resum de KPIs del Quadre de Comandament Power BI	Pàg. 38
Figura 9. Pàgina principal Quadre de Comandament Power BI	Pàg. 39
Figura 10. Pàgina secundària Quadre de Comandament BI	Pàg. 40
Figura 11. Traçabilitat entre objectius i l'obtingut	Pàg. 41
Figura 12. Comparativa de qualitat de dades: pre-ETL vs. post-ETL	Pàg. 49
Figura 13. Evolució de l'Schema Drift per variable i any	Pàg. 50
Figura 14. Diccionari de Dades complet	Pàg. 54
Figura 15. Coeficients d'interferència per al càlcul del KPI CPP	Pàg. 55

1. Introducció

El treball consistirà en el desenvolupament d'una solució de Business Intelligence i analítica predictiva basada en Python, bases de dades i Power BI per avaluar l'impacte de la salut mental en el rendiment laboral i la retenció de talent, sobretot en el sector tecnològic. En primer lloc, es crearà un conjunt de dades consolidat a partir de diferents datasets públics històrics de l'OSMI, al qual s'integraran variables organitzatives generades de forma sintètica.

Després de creuar, netejar i homogeneïtzar aquestes dades mitjançant un procés ETL (per resoldre problemes com la deriva d'esquema), es dissenyarà l'arquitectura del Data Warehouse i es realitzaran les transformacions necessàries per optimitzar el model. Durant aquesta fase de neteja s'escolliran exclusivament aquelles variables més rellevants, estandarditzant les preguntes per reduir l'efecte soroll que es produeix amb l'elevat nombre de columnes redundants de les enquestes originals.

Una vegada optimitzat el model de dades, s'explotarà mitjançant quadres de comandament interactius i models d'anàlisi per avaluar-ne l'eficàcia a l'hora de respondre a les preguntes de negoci i KPIs definits.

1.1. Context i justificació del Treball

En l'actualitat, la salut mental en l'àmbit laboral s'ha convertit en un repte estratègic de primer ordre. El sector tecnològic creix a un ritme molt accelerat i es troba sota una pressió constant per innovar. Aquest dinamisme moltes vegades té un impacte directe en el benestar dels professionals que hi treballen. L'alta exigència cognitiva, la pressió pels terminis d'entrega, la síndrome de l'impostor o l'aïllament vinculat al teletreball han contribuït a augmentar els problemes de salut mental. Específicament en el sector tecnològic, aquests factors han disparat els índexs de burnout (síndrome del treballador cremat).

Tot i que moltes organitzacions recullen dades mitjançant enquestes de clima laboral, com les realitzades anualment per la fundació OSMI (Open Sourcing Mental Illness), sovint manca una infraestructura tecnològica capaç de transformar aquesta informació heterogènia en coneixement accionable. Aquest conjunt de dades presenta característiques habituals en entorns reals: heterogeneïtat en les preguntes segons l'any, valors absents, formats inconsistents i informació desestructurada.

Per tal d'enriquir el projecte i dotar-lo d'una autèntica visió de *Business Intelligence* i *HR Analytics*, la informació clínica d'OSMI s'integrarà amb dades financeres i de recursos humans generades sintèticament (salari anual per empleat, departament, hores extres realitzades i un indicador de rendiment de l'1 al 5). Aquesta hibridació de dades permetrà anar més enllà de la salut mental i avaluar l'impacte directe del *burnout* en el compte de resultats de l'empresa (pèrdua de productivitat, fugues de talent clau, etc.). Aquesta quantificació és fonamental per a les empreses, ja que, tal com assenyala l'Organització Mundial de la Salut (**WHO, 2022**), els problemes de salut mental costen anualment bilions a l'economia global precisament per la pèrdua de productivitat.

Des de l'Enginyeria del Programari, aquest projecte aborda la complexitat de dissenyar una arquitectura de Business Intelligence completa (End-to-End). Això no només implica la visualització final, sinó la resolució de reptes tècnics com la ingesta i normalització de dades mitjançant processos ETL automatitzats en Python, el disseny d'un magatzem de dades (Data Warehouse) i la implementació d'algorismes de Machine Learning per predir tendències de risc psicosocial. La utilitat del projecte resideix en la seva capacitat per dotar les organitzacions d'una eina objectiva que permeti identificar patrons de risc, predir tendències d'abandonament laboral i avaluar l'impacte real de les polítiques de benestar.

Explicació de la motivació personal

El sector tecnològic creix a un ritme molt accelerat i els professionals que hi treballem estem sota una pressió constant per innovar i complir expectatives. Aquest dinamisme, sumat a l'alta exigència cognitiva, la pressió pels terminis d'entrega, la síndrome de l'impostor o l'aïllament sovint vinculat al teletreball, té un impacte directe en el nostre benestar diari.

He viscut i observat com aquests factors afavoreixen l'augment silencios de problemes de salut mental en el nostre entorn professional, destacant especialment l'estrès crònic i el *burnout*. He triat aquest tema per al meu Treball Final de Grau perquè crec fermament que podem i hem d'utilitzar la tecnologia per cuidar de les persones que la creen.

La integració de tècniques d'Enginyeria de Dades i *Business Intelligence* aplicades a l'àmbit dels Recursos Humans (*People Analytics*) em sembla una oportunitat fascinant per objectivar una realitat que sovint queda invisibilitzada o es tracta com un tema tabú. La meva motivació principal per desenvolupar aquest projecte és demostrar que l'anàlisi avançada de dades no només serveix per optimitzar beneficis econòmics o operatius, sinó que pot i ha de ser una eina fonamental per detectar riscos psicosocials de manera proactiva, ajudant les organitzacions a prendre decisions més empàtiques i a millorar realment la qualitat de vida als entorns corporatius.

1.2. Objectius del Treball

- L'Objectiu principal (**OP**) es basa en dissenyar i desenvolupar un sistema complet d'intel·ligència de negoci (BI) que integri dades històriques sobre salut mental i dades sintètiques de caràcter organitzatiu (HR Analytics) en l'entorn tecnològic, per facilitar la presa de decisions estratègiques i avaluar l'impacte econòmic del benestar laboral.
- Objectius secundaris(**OSx**).

ID	DESCRIPCIÓ
OS1	Anàlisi i unificació de fonts de dades: Analitzar i unificar fonts de dades obertes (datasets OSMI 2016-2023), resolent problemes de qualitat i canvis estructurals entre els diferents anys per evitar la deriva d'esquema (<i>Schema Drift</i>).
OS2	Generació de dades sintètiques: Desenvolupar un mòdul mitjançant Python (NumPy) per simular variables crítiques de Recursos Humans i Finances: salari anual, departament (Backend, Frontend, DevOps, etc.), hores extres realitzades i un indicador de rendiment (escala 1-5).
OS3	Disseny i implementació de processos ETL: Utilitzar Python (Pandas) per dur a terme l'Extracció, Transformació i Càrrega (ETL), garantint la neteja i normalització de les dades de l'OSMI i la seva integració amb les dades sintètiques en un dataset centralitzat.
OS4	Modelatge de Data Warehouse: Dissenyar un magatzem de dades seguint la metodologia dimensional de Ralph Kimball (esquema en estrella) per garantir un rendiment òptim de les consultes analítiques que creuran dades clíniques amb organitzatives.
OS5	Desenvolupament de model d'Analítica Predictiva: Entrenar i validar un model de <i>Machine Learning</i> mitjançant Scikit-Learn per classificar la probabilitat de patir <i>burnout</i> basant-se en l'entorn de treball i les noves variables de càrrega laboral.

OS6	Implementació de Quadre de Comandament (BI): Desenvolupar un <i>Dashboard</i> interactiu a Power BI que permeti la visualització de KPIs de negoci d'alt valor (Cost de pèrdua de productivitat, Mapa de risc per departament, Correlació d'hores extres i Risc de fuga de talent clau).
-----	--

Figura 1. Taula amb els objectius secundaris del projecte

1.3. Impacte en sostenibilitat, ètic-social i de diversitat

En aquest apartat identifiquem els possibles impactes del treball en les tres dimensions de la competència de compromís ètic i global (CCEG) promoguts per la UOC, amb l'objectiu d'estar alineat amb els Objectius de Desenvolupament Sostenible (ODS) de la ONU.

Sostenibilitat

Aquest treball té un impacte positiu en la sostenibilitat social i econòmica, alineant-se amb l'ODS 3 (Salut i Benestar) i l'ODS 8 (Treball digne i creixement econòmic). L'eina desenvolupada permet visibilitzar l'impacte de la salut mental en l'entorn laboral, la qual cosa pot ajudar les organitzacions a reduir costos derivats de la rotació de personal i la pèrdua de productivitat. En optimitzar el benestar dels treballadors, es fomenta un creixement econòmic més humà i sostenible a llarg termini.

Pel que fa a la sostenibilitat ambiental, la pròpia elaboració del treball requereix el processament de grans volums de dades i l'entrenament de models de Machine Learning. Aquest procediment és demandant de recursos computacionals (CPU, RAM i emmagatzematge), el que implica un consum energètic. Per minimitzar aquest impacte, s'ha prioritzat l'ús d'algoritmes eficients i un disseny de Data Warehouse optimitzat (esquema en estrella) que redueix la redundància de dades i el temps de processament de les consultes, minimitzant així la petjada de carboni digital del projecte.

Comportament ètic i responsabilitat social (RS)

El projecte presenta un fort component de responsabilitat social en abordar l'estigma de la salut mental en el sector tecnològic. L'impacte ètic és positiu, ja que busca transformar la cultura empresarial cap a una major transparència i suport emocional. Un aspecte crític en aquesta dimensió és l'ús de dades: malgrat treballar amb un dataset obert i anonimitzat (OSMI), s'ha posat especial cura a garantir que la informació no permeti la reidentificació d'individus.

Així mateix, l'ús de dades sintètiques s'aborda amb la màxima responsabilitat ètica, assegurant que aquestes s'utilitzen exclusivament per simular escenaris de negoci i no per suplantar o falsejar realitats clíniques, mantenint la integritat de les conclusions del treball.

Diversitat (de gènere, entre d'altres) i drets humans

Pel que fa a la diversitat, el projecte té un impacte directe en la identificació de biaixos dins del sector tech, tradicionalment masculinitzat. L'anàlisi de dades inclou dimensions de gènere, edat i orientació sexual (variables presents a les enquestes OSMI) per entendre com els problemes de salut mental afecten de manera diferenciada als col·lectius minoritaris.

L'eina està dissenyada per promoure el dret humà a un entorn de treball saludable i segur, sense discriminació. En analitzar la "por a conseqüències professionals" segons diferents perfils demogràfics, el treball contribueix a crear estratègies d'inclusió que protegeixen els drets dels treballadors més vulnerables dins de les organitzacions tecnològiques.

1.4. Enfocament i mètode seguit

Aquest projecte s'aborda des d'una perspectiva d'Enginyeria de Dades i Business Intelligence (BI), amb un enfocament marcadament quantitatiu i analític. L'objectiu no és només la visualització de dades, sinó la creació d'un ecosistema robust que integri fonts reals i sintètiques per donar suport a la presa de decisions estratègiques.

Per al desenvolupament del component de Business Intelligence i la construcció del Data Warehouse, s'utilitzarà la metodologia **HEFESTO v2.0**, complementada amb els principis de disseny dimensional de Ralph Kimball. El projecte s'estructura en les següents fases d'execució:

- Definició de les preguntes de negoci i disseny dels KPIs financers i de Recursos Humans (Cost de pèrdua de productivitat, taxa de burnout, etc.).

- Exploració exhaustiva i perfilat de les dades obertes (OSMI) mitjançant Python per identificar inconsistències (*Schema Drift*), així com la definició de l'estructura de les dades sintètiques a generar.
- Disseny multidimensional utilitzant un esquema en estrella (*Star Schema*) preparat per acollir i relacionar eficientment tant les dades clíniques com les organitzatives.
- Ús programàtic de Python (llibreries Pandas i NumPy) per a la neteja de les dades reals i la injecció algorítmica de les dades fictícies (*Mock Data*: salari, rendiment, hores extres i departament) per unificar-les al magatzem de dades..
- Integració del model consolidat a Power BI i desenvolupament del Quadre de Comandament interactiu, utilitzant el llenguatge DAX per a mètriques calculades complexes.
- Aplicació de tècniques de Machine Learning per classificar la probabilitat de patir burnout, afegint valor predictiu més enllà de l'analítica descriptiva convencional.

Per a la gestió global del projecte, s'adoptarà una planificació clàssica lligada a l'avaluació contínua de la UOC. El seguiment temporal i el control de desviacions es durà a terme mitjançant l'ús d'un Diagrama de Gantt, establint punts de control (fites) que coincideixen amb els lliuraments de les PACs per garantir l'assoliment dels objectius dins del termini establert.

A més a més, tot el procés, malgrat ser incremental, estarà sotmès a revisió contínua, per la qual cosa, en qualsevol moment del treball podem haver de revisar o modificar alguns dels punts, treballs o productes que s'havien finalitzat anteriorment.

1.5. Planificació del Treball

La planificació del treball s'ha elaborat ajustant-se a les fites dels lliuraments parcials. Tot seguit, es mostra la planificació del projecte i el diagrama de Gantt. La planificació s'estructura en 5 blocs temporals alineats amb l'avaluació contínua:

Fase 1: Iniciació i Planificació (PAC 1) [23/02/2026 - 08/03/2026]

- T1.1: Definició de l'abast i objectius (23/02 - 27/02)

- T1.2: Selecció de l'stack tecnològic (28/02 - 03/03)
- T1.3: Redacció del Pla de Treball PAC 1 (04/03 - 08/03)

Fase 2: Anàlisi i Disseny de l'Arquitectura (PAC 2) [09/03/2026 - 08/04/2026]

- T2.1: Descàrrega OSMI i Data Profiling (09/03 - 16/03)
- T2.2: Definició de KPIs i preguntes de negoci (17/03 - 21/03)
- T2.3: Disseny conceptual del procés ETL (22/03 - 30/03)
- T2.4: Modelatge dimensional: Esquema en estrella (31/03 - 05/04)
- T2.5: Redacció i tancament document PAC 2 (06/04 - 08/04)

Fase 3: Implementació, ML i Dashboard (PAC 3) [09/04/2026 - 10/05/2026]

- T3.1: Creació i configuració de la Base de Dades (09/04 - 13/04)
- T3.2: Programació scripts ETL en Python i generació de dades sintètiques (salari, departament, hores, rendiment) (14/04 - 23/04)
- T3.3: Entrenament del model Machine Learning (24/04 - 30/04)
- T3.4: Desenvolupament Dashboard Power BI (01/05 - 08/05)
- T3.5: Redacció i tancament document PAC 3 (09/05 - 10/05)

Fase 4: Tancament i Memòria Final (PAC 4) [11/05/2026 - 07/06/2026]

- T4.1: Redacció de la memòria completa (11/05 - 28/05)
- T4.2: Revisió de format i bibliografia (29/05 - 03/06)
- T4.3: Empaquetat de codi i lliurables PAC 4 (04/06 - 07/06)

Fase 5: Defensa del Projecte (PAC 5) [08/06/2026 - 23/06/2026]

- T5.1: Preparació de diapositives de presentació (08/06 - 14/06)
- T5.2: Assaig i gravació del vídeo de defensa (15/06 - 21/06)
- T5.3: Revisió final i lliurament PAC 5 (22/06 - 23/06)




Figura 2. Diagrama de Gantt amb la planificació del projecte

1.6. Breu sumari de productes obtinguts

A partir dels resultats, presentaré l'anàlisi de les **conclusions** del treball, avaluant l'eficàcia i valorant la consecució dels objectius. En aquest apartat inclouré una revisió de la feina realitzada, així com les properes línies de treball futures a partir dels resultats obtinguts.

Aquests seran els productes del treball:

1. Memòria de TFG.
2. *Dataset* que fusiona la informació clínica neta de l'OSMI amb les variables organitzatives sintètiques generades..
3. Conjunt de fitxers i scripts desenvolupats en Python (utilitzant llibreries com Pandas, NumPy i Scikit-Learn) encarregats del *Data Profiling*, la transformació de dades (resolució de l'*Schema Drift*) i l'entrenament del model predictiu.
4. Data Warehouse implementada seguint un model dimensional en estrella (Star Schema).
5. Quadre de comandament que conté el model de dades relacional, les mesures DAX creades i els panells visuals (Dashboards) preparats per a l'usuari final.
6. Presentació del TFM (diapositives, vídeo)

1.7. Breu descripció dels altres capítols de la memòria

El següent apartat, **Materials i mètodes**, detalla l'estudi de les fonts de dades (OSMI) i l'especificació tècnica de la solució. Aquest capítol serveix com a punt de partida per definir les preguntes de negoci i els KPIs corporatius, així com per descriure detalladament els processos d'enginyeria de dades (ETL) i el modelatge dimensional (esquema en estrella) necessaris per construir el *Data Warehouse*.

El tercer apartat se centra en la descripció dels **Resultats**, o productes del treball, i es divideix en les següents parts:

1. Extracció, neteja i transformació de les dades històriques mitjançant scripts de Python, resolent problemes estructurals com la deriva d'esquema (*Schema Drift*).
2. Generació i injecció de dades organitzatives sintètiques (salari, hores extres, departament i rendiment).

3. Construcció del *Data Warehouse* segons el model dimensional dissenyat prèviament.
4. Elaboració i optimització del model predictiu (*Machine Learning*) per classificar el risc de *burnout*.
5. Desenvolupament i presentació del Quadre de Comandament interactiu (Power BI) per a la visualització eficaç dels resultats i monitoratge dels KPIs.

A partir dels resultats, presentaré a l'apartat de **Conclusions i treballs futurs** l'anàlisi de les conclusions del treball, avaluant l'eficàcia del sistema i valorant la consecució dels objectius. En aquest apartat inclouré una revisió crítica de la feina realitzada, així com les properes línies de treball futures a partir dels resultats obtinguts per seguir millorant l'eina.

Finalment, s'inclouen la el **glossari**, la **bibliografia** i els **annexos**.

1.8. Declaració sobre l'ús d'intel·ligència artificial generativa

D'acord amb la normativa acadèmica vigent, es fa constar l'ús del model de llenguatge **Google Gemini** com a eina de suport durant el desenvolupament d'aquest Treball Final de Grau, el qual s'ha realitzat seguint les indicacions i amb el coneixement del tutor/a.

Aquesta eina s'ha utilitzat exclusivament amb finalitats d'assistència tècnica i d'edició durant les fases de desenvolupament i redacció. Concretament, s'ha emprat per a la depuració d'esbossos de codi en Python (ajuda amb la sintaxi de les llibreries Pandas i NumPy per al procés ETL i generació de dades sintètiques), així com per a la revisió ortotipogràfica, correcció gramatical i millora de la fluïdesa del text d'aquesta memòria en català.

S'aclareix explícitament que la presa de decisions estratègiques (metodologies, definició de KPIs), l'anàlisi de dades i les conclusions són d'autoria íntegra i exclusiva de l'estudiant. Tots els suggeriments tècnics o gramaticals generats per la IA han estat contrastats, executats en entorns locals per validar-ne el funcionament i revisats manualment. Per tant, la responsabilitat intel·lectual i la validació final de la totalitat del contingut d'aquest treball recauen exclusivament sobre mi (autor de la memòria).

2. Materials i mètodes

2.1. Revisió de l'estat de l'art (Metodologia PRISMA)

Per establir una base teòrica sòlida i garantir el rigor en l'elecció de les tècniques d'anàlisi de dades, s'ha realitzat una revisió sistemàtica de la literatura aplicant directrius basades en la metodologia **PRISMA** (*Preferred Reporting Items for Systematic Reviews and Meta-Analyses*) (**Page, 2021**). L'objectiu ha estat analitzar treballs previs sobre l'ús del *Business Intelligence* i el *Machine Learning* aplicats al benestar laboral en el sector tecnològic.

S'ha dut a terme una cerca exhaustiva en bases de dades acadèmiques utilitzant cadenes booleanes com ("*mental health*" OR "*burnout*") AND ("*tech sector*") AND ("*machine learning*" OR "*predictive analytics*"). Es van aplicar criteris d'inclusió estrictes: estudis publicats entre 2014 i 2026, enfocats exclusivament en professionals TIC, i que aportessin solucions predictives o d'arquitectura de dades.

Diversos estudis recents (**Reddy, 2018**), (**Katarya, 2022**) corroboren que els models d'aprenentatge automàtic supervisat (com *Random Forest*, *XGBoost* o Regressió Logística) són altament efectius per predir l'estrès i l'ansietat en els desenvolupadors. L'anàlisi algorítmica sobre les dades de l'OSMI assenyala de forma empírica que factors com la manca de polítiques de benestar a l'empresa, la interferència del treball en la vida personal i les hores de sobrecàrrega actuen com als predictors principals de l'esgotament emocional.

La revisió confirma l'eficàcia de models predictius (**Memon, 2023**) per avaluar l'estrès mitjançant conjunts de dades oberts com l'OSMI, destacant l'impacte de les "hores de sobrecàrrega" com a predictor principal.

Després de la revisió hem comprovat que, si bé hi ha molts models matemàtics aïllats que estudien la salut mental, hi ha molt pocs treballs que integren aquestes prediccions clíniques en *Data Warehouses* relacionats amb el departament de Recursos Humans (salaris, departaments) per ser analitzats via Quadres de Comandament.

Aquesta es la proposta de valor que m'agradaria cobrir amb el TFG.

2.2. Metodologia triada, alternatives i presa de decisions

Per a la construcció d'aquest ecosistema analític, s'han pres decisions estructurals fonamentals a nivell de cicle de vida del projecte i d'arquitectura de dades:

A) Cicle de desenvolupament: Metodologia HEFESTO v2.0 En l'àmbit de l'enginyeria de dades, és comú l'ús de la metodologia CRISP-DM (*Cross-Industry Standard Process for Data Mining*). No obstant això, es va descartar com a marc principal perquè està orientada al descobriment de patrons ocults i no ofereix directrius procedimentals per a la construcció estructurada de magatzems de dades corporatius.

En el seu lloc, **s'ha optat per la metodologia HEFESTO v2.0 (Bernabeu, 2010)**. Aquesta decisió es justifica pel fet que HEFESTO és un marc de treball àgil dissenyat específicament per a la construcció de projectes de *Business Intelligence* (BI). La seva principal virtut és que utilitza un enfocament de "dalt a baix" (*Top-Down* a nivell de negoci), posant l'usuari final al centre de l'arquitectura.

La seva aplicació en aquest projecte es divideix en quatre fases iteratives:

1. **Anàlisi de requeriments de negoci:** Identificació de la necessitat real (mesurar l'impacte del *burnout* en l'entorn *tech*) i definició teòrica dels indicadors (KPIs).
2. **Anàlisi de fonts de dades:** Exploració tècnica de les enquestes OSMI per determinar quina informació existeix i quina s'ha de generar de manera sintètica.
3. **Modelatge Conceptual i Lògic:** Disseny de les taules i les seves relacions.
4. **Procés ETL i Poblament:** Construcció automatitzada de la base de dades.

B) Modelatge de dades: L'enfocament dimensional de Ralph Kimball pel que fa al disseny físic del magatzem de dades, la teoria clàssica presenta dos grans paradigmes: l'Enterprise Data Warehouse d'Inmon i el modelatge dimensional de Kimball. Es va descartar l'enfocament de Bill Inmon (basat en magatzems altament normalitzats en Tercera Forma Normal, 3NF) a causa de la seva complexitat excessiva, que alenteix dràsticament el rendiment de les consultes en sistemes analítics.

Per tant, **s'ha adoptat la metodologia *Bottom-Up* de Ralph Kimball (Kimball i Ross, 2013)**. Aquest enfocament defensa la construcció de *Data Marts* específics modelats mitjançant un **Esquema en Estrella** (*Star Schema*). El criteri de selecció radica en els següents principis tècnics:

- **Desnormalització intencionada:** La informació redundant es permet a les taules de dimensions per evitar múltiples operacions JOIN complexes (típiques dels sistemes transaccionals OLTP), optimitzant el sistema per a la lectura analítica (OLAP).
- **Eficiència en el motor BI:** Aquesta arquitectura és el format natiu requerit pel motor VertiPaq de Power BI, garantint la màxima compressió de dades i un rendiment òptim en els càlculs DAX interactius que realitzarà l'usuari.

2.3. Definició de KPIs i preguntes de negoci.

D'acord amb la primera fase de la metodologia HEFESTO, abans d'iniciar el desenvolupament del *Data Warehouse* s'han formalitzat els Indicadors Clau de Rendiment (KPIs). Aquests indicadors permetran donar resposta a les necessitats estratègiques de l'empresa, transformant les respostes clíniques de l'enquesta OSMI i les dades sintètiques generades en mètriques accionables. S'han definit els següents quatre KPIs principals:

1. Cost de pèrdua de productivitat (CPP):

Aquest indicador econòmic es calcula a partir de la relació directa entre el salari sintètic anual del treballador i la interferència laboral real reportada a causa de problemes de salut mental. Per a un empleat i , es modelitza matemàticament com:

$$CPP_i = \text{Salari_Anual}_i \times \text{Coeficient_Interferència}_i$$

On el coeficient d'interferència pren valors ordinals predefinits basats en les respostes clíniques (per exemple, "Sovint" = 0.20 de pèrdua, "De vegades" = 0.10, "Mai" = 0.0). El CPP total del quadre de comandament serà l'agregació d'aquest cost per a tota la plantilla.

2. Mapa de risc per departament:

Té com a objectiu la identificació de les àrees tècniques amb major índex de *burnout*. Per calcular aquest índex, s'analitzarà la proporció de treballadors afectats en cada departament d (Backend, Frontend, DevOps, etc.):

$$\text{Risc_Dept}_d = \left(\frac{\text{Empleats al departament } d \text{ amb símptomes reportats}}{\text{Total empleats al departament } d} \right) \times 100$$

Aquest indicador permetrà generar un mapa de calor visual per classificar quines àrees de l'organització necessiten una intervenció prioritària de Recursos Humans.

3. Correlació d'hores extres:

Avalua l'impacte de l'excés de jornada laboral en la sol·licitud de tractament professional. Aquest indicador estadístic mesura com incrementa la probabilitat de necessitar assistència psicològica en funció de les hores extres setmanals (h) realitzades:

$$\text{Ràtio_Tractament} = \frac{P(\text{Tractament} \mid h > 5)}{P(\text{Tractament} \mid h \leq 5)}$$

Aquesta relació evidenciarà empíricament si la sobrecàrrega de treball actua com el detonant principal de l'esgotament.

4. Risc de fuga de talent clau (RFTC)

Permet el monitoratge dels treballadors amb alt rendiment que presenten símptomes de fatiga crònica o por a represàlies. És un indicador crític per a la retenció estratègica de personal, calculant-se exclusivament sobre el subconjunt d'empleats avaluats amb un rendiment superior ($R \geq 4$):

$$\text{RFTC} = \left(\frac{\text{Talent Clau amb interferència per fatiga}}{\text{Total Talent Clau}} \right) \times 100$$

Un augment en aquest KPI actua com a alerta primerenca de pèrdua imminent de professionals estratègics per a l'empresa.

2.4. Descàrrega OSMI i Data Profiling (Anàlisi Exploratori)

L'obtenció i la comprensió profunda de les dades crues (*raw data*) és la fase crítica que determina l'estratègia de neteja posterior. Aquesta fase s'ha dividit en la ingesta de les fonts primàries i el posterior perfilat de dades (*Data Profiling*).

2.4.1. Origen i Ingesta de Dades

La font d'informació primària prové de les enquestes anuals *Mental Health in Tech Survey*, realitzades entre els anys 2014 i 2023. Aquests conjunts de dades s'han descarregat del repositori obert de Kaggle, publicats i anonimitzats originalment per la fundació OSMI (*Open Sourcing Mental Illness*).

La ingesta inicial va consistir en la descàrrega de múltiples fitxers en format .csv independents (un per a cada any d'enquesta). Abans d'aplicar qualsevol transformació, l'agrupació vertical bruta d'aquests arxius formava un conjunt de dades original de més de 4.700 registres (respostes d'empleats del sector tecnològic).

2.4.2. Procés de Data Profiling

Per avaluar la qualitat de les dades, identificar patrons, anomalies i distribucions estadístiques, es va dur a terme una Anàlisi Exploratori de Dades (EDA) automatitzada i manual utilitzant Python. L'entorn de treball es va basar en la llibreria Pandas per a l'estructuració tabular, recolzada per l'eina ydata-profiling (anteriorment *Pandas Profiling*), la qual va generar informes interactius en format HTML amb anàlisis univariants i bivariants de cada variable.

Aquest perfilat va revelar tres problemàtiques estructurals crítiques que impossibilitaven l'ús directe de les dades per a *Business Intelligence* o *Machine Learning*:

1. Identificació de la Deriva d'Esquema (Schema Drift):

La troballa més rellevant del *profiling* va ser la confirmació d'un problema sever de deriva d'esquema (*Schema Drift*). Aquest fenomen es produeix quan l'estructura d'origen de les dades canvia de manera impredecible amb el pas del temps.

En el cas de l'OSMI, les preguntes del formulari van evolucionar i es van reformular gairebé cada any. Per exemple, la pregunta de 2014 *"Do you have a mental health condition?"* va ser substituïda el 2017 per *"Have you ever been diagnosed with a mental health disorder?"*. En realitzar la concatenació d'arxius (pd.concat de Pandas), el sistema va tractar cada formulació diferent com una nova variable, expandint l'eix horitzontal del dataset fins a generar **214 columnes** totalment desestructurades i semànticament redundants.

2. Alta Esparsitat i Valors Nuls (NaN)

Com a conseqüència directa de l'*Schema Drift*, el conjunt de dades presentava una matriu altament dispersa (*Sparse Matrix*). Atès que una pregunta introduïda l'any 2018 no existia en l'arxiu de 2014, tots els registres anteriors a 2018 per a aquella columna s'omplien automàticament amb valors nuls (NaN).

L'informe del *Data Profiling* va alertar que més del 65% de les cel·les totals de la matriu de 214 columnes estaven buides. Aquesta dispersió no només desvirtua qualsevol anàlisi estadística, sinó que l'elevat consum de memòria RAM en processar estructures tan amples i buides generava errors de rendiment (*Memory Leaks*).

3. Inconsistència de Tipus de Dades

El perfilat va evidenciar formats inconsistents (per exemple, edats introduïdes com a nombres negatius o superiors a 100 per errors de tecleig dels usuaris) i camps de text lliure que haurien de ser variables categòriques (com el gènere, on els usuaris van introduir més de 40 variacions de text diferents per definir "Home" o "Dona").

El diagnòstic d'aquesta fase va dictaminar la necessitat d'aturar l'anàlisi analítica i retrocedir per dissenyar un procés ETL programàtic (basat en un diccionari de mapeig) per reduir, unificar i netejar les dades, tal com es detalla a l'apartat següent.

2.5. Disseny conceptual i desenvolupament del procés ETL

Per donar resposta als KPIs establerts i solucionar la complexitat estructural detectada durant el *Data Profiling* (deriva d'esquema i valors nuls), s'ha dissenyat i programat un *pipeline* ETL (Extract, Transform, Load) completament automatitzat.

Aquest procés s'ha dut a terme utilitzant scripts en Python, amb un ús intensiu de les llibreries Pandas per gestionar i transformar dades tabulars, i NumPy per realitzar càlculs numèrics i generar valors aleatoris.

El procés s'ha estructurat en les següents subfases:

2.5.1. Fase d'Extracció (Extract)

La fase inicial consisteix en la ingesta programàtica dels diferents arxius .csv corresponents a cada any de l'enquesta OSMI. Mitjançant la funció de lectura de Pandas, els arxius es carreguen en memòria com a *DataFrames* independents i es concatenen verticalment. En aquesta fase s'assumeix temporalment la creació de la matriu dispersa de 214 columnes descrita anteriorment, per tal de no perdre cap informació de la font primària.

2.5.2. Fase de Transformació i Neteja (Transform)

Aquesta és l'etapa més crítica del *pipeline*, on s'apliquen regles de negoci i procediments de qualitat de dades per estandarditzar la informació:

- **Resolució de l'Schema Drift (Mapeig Semàntic):** S'ha programat un diccionari de dades dinàmic en Python. Aquest diccionari actua com a taula d'equivalències per fusionar diferents columnes que pregunten el mateix però amb diferent text (ex. "What is your age?" i "Age" es mapegen cap a una única variable estàndard: edat). Això ha permès reduir dràsticament la dimensionalitat de 214 a només 12 variables clíniques i demogràfiques rellevants per a l'estudi, eliminant el 90% dels valors nuls estructurals.

- **Normalització de Variables Demogràfiques:**
 - **Edat:** S'ha aplicat un filtre de valors atípics (*Outliers*), eliminant registres amb edats invàlides (inferiors a 18 o superiors a 100 anys) derivats d'errors d'introducció manual.
 - **Gènere:** Es va dissenyar una funció basada en expressions regulars (*RegEx*) per agrupar les més de 40 entrades de text lliure introduïdes pels usuaris (ex. "Male", "m", "cis male") en tres úniques categories estandarditzades: Masculí, Femení i Altres/No-Binari.
- **Imputació de Valors Nuls (Missing Values):** Per a les variables clíniques (com la interferència del tractament en la feina), els valors buits s'han tractat mitjançant tècniques d'imputació o categoritzant-los sota l'etiqueta "No Respon/Desconegut", garantint així que no es perdi volum de dades (*Row Dropping*) útil per als algorismes de *Machine Learning*.

2.5.3. Fase d'Enriquiment i Generació Sintètica (Mock Data)

Atès que el dataset de l'OSMI és de caràcter exclusivament clínic, mancava de les variables organitzatives necessàries per calcular indicadors corporatius com el Cost de Pèrdua de Productivitat (CPP) o el Risc per Departament. Per resoldre-ho, el procés ETL incorpora un mòdul d'enriquiment que injecta variables generades algorítmicament mitjançant funcions de distribució probabilística de NumPy:

- **Salari Anual:** Salari Anual: Simulat mitjançant una distribució Normal $N(\mu, \sigma^2)$, ajustant la mitjana (μ) i la desviació estàndard (σ) a valors realistes del sector tecnològic (ex. $\mu = 65.000$ EUR).
- **Hores Extres Setmanals:** Per modelar un comportament realista on la majoria de treballadors fan poques hores extres però alguns en fan moltes (cues llargues), s'ha utilitzat una distribució de Poisson $P(\lambda)$, sent λ la taxa mitjana d'hores extra esperades.
- **Departament i Rendiment:** Assignació de departaments (*Backend*, *Frontend*, *DevOps*, *Data*, *HR/Management*) i d'una nota d'avaluació de l'acompliment o rendiment (variable discreta de l'1 al 5) utilitzant seleccions ponderades per replicar l'estructura típica d'una empresa de desenvolupament de programari.

2.5.4. Fase de Càrrega (Load)

Una vegada completades la neteja i la injecció de dades sintètiques, el *DataFrame* resultant adquireix la seva forma definitiva.

En aquesta darrera subfase, la taula s'exporta i s'emmagatzema físicament com a arxiu mestre (osmi_unificat_NET_SINTETIC.csv).

Aquest arxiu consolidat consta de 4.701 registres completament sans i 17 variables, actuant com a font de veritat única (*Single Source of Truth*) que alimentarà l'Esquema en Estrella descrit a l'apartat següent.

2.6. Modelatge dimensional: Esquema en estrella.

Un cop consolidat el dataset net i enriquit mitjançant el procés ETL, la següent fase segons la metodologia de Ralph Kimball consisteix a transformar aquesta estructura plana en un **model dimensional**. L'objectiu és optimitzar la base de dades per a la consulta analítica i facilitar la creació de mètriques complexes en l'eina de visualització (Power BI).

Per a aquest projecte, s'ha dissenyat un **Esquema en Estrella** (*Star Schema*). Aquesta arquitectura es caracteritza per tenir una taula central que recull els esdeveniments quantificables (fets) connectada a diverses taules perifèriques que contenen els atributs descriptius (dimensions).

2.6.1. Taula de Fets: *Fets_Rendiment_Benestar*

És el nucli del model i emmagatzema les dades numèriques o mètriques (mecanismes de mesura) que seran agregades. Cada registre d'aquesta taula representa la situació laboral i clínica d'un empleat en un moment donat. Les mètriques clau incloses són:

- **Mètriques Salarials:** Salari anual (sintètic) per al càlcul del CPP.
- **Mètriques Temporals:** Hores extres setmanals (sintètiques).
- **Mètriques d'Acompliment:** Nota de rendiment (1-5).
- **Claus Foranes (FK):** Identificadors que connecten amb cada una de les dimensions.

2.6.2. Taules de Dimensions

Les dimensions proporcionen el context "qui, on, quan i com" de les dades. S'han definit cinc dimensions desnormalitzades per permetre operacions de *drill-down* i *filtering*:

Dim_Temps: Permet l'anàlisi longitudinal i comparativa entre els diferents anys d'execució de les enquestes (2014-2023).

Dim_Demografia: Conté atributs personals com l'edat (agrupada per franges), el gènere normalitzat i el país de residència.

Dim_Entorn_Laboral: Inclou variables de context professional com el departament tecnològic, la mida de l'organització, el tipus de treball (remot/presencial) i el rol tècnic.

Dim_Salut_Mental: Recull l'estat clínic de l'empleat, incloent-hi si té un diagnòstic confirmat, si rep tractament actiu i el nivell d'interferència que aquests problemes causen en la seva feina.

Dim_Cultura_Empresa: Agrupa variables d'opinió i percepció, com la facilitat per demanar la baixa per salut mental, l'anonimat en els recursos d'ajuda i la por a patir represàlies o conseqüències professionals.

2.6.3. Avantatges Tècnics del Disseny

L'elecció d'aquest esquema no és arbitrària, sinó que respon a tres criteris tècnics fonamentals:

1. **Rendiment del motor VertiPaq:** Power BI utilitza un motor d'emmagatzematge columnar que assoleix la màxima eficiència en compressió i velocitat quan les relacions són de tipus "un a molts" (1:*) des de les dimensions cap als fets, tal com dicta l'esquema en estrella.
2. **Simplicitat en el llenguatge DAX:** Un model ben dimensionat redueix la complexitat de les fórmules DAX (*Data Analysis Expressions*), evitant l'ús excessiu de funcions de navegació entre taules i garantint la integritat dels resultats.
3. **Usabilitat per a l'usuari final:** En presentar les dades organitzades per entitats lògiques (Temps, Empleat, Empresa), els responsables de Recursos Humans poden explorar la informació de manera intuïtiva sense necessitat de conèixer l'estructura tècnica subjacent.

2.7. Descripció dels productes obtinguts

Com a resultat directe de l'aplicació de la metodologia HEFESTO i de l'execució de les fases d'enginyeria de dades descrites en aquest capítol, s'han generat diversos lliurables tècnics. Aquests productes constitueixen la base funcional sobre la qual es desenvoluparà la fase d'explotació analítica i predicció. Fins a l'estat actual del projecte, els productes tangibles obtinguts són els següents:

1. Dataset Consolidat i Enriquit (Data Warehouse Lògic):

El principal actiu de dades obtingut és l'arxiu mestre denominat `osmi_unificat_NET_SINTETIC.csv`. Aquest arxiu és el resultat final del procés ETL i representa la base de dades neta, normalitzada i modelada. Està format per **4.701 registres** (treballadors únics) i una reducció d'alta qualitat a **17 variables estandarditzades**. Aquest producte té un gran valor afegit, ja que fusiona amb èxit la informació clínica real de l'OSMI amb les variables corporatives (salari, rendiment, hores extres) generades sintèticament, conformant un conjunt de dades preparat directament per al *Business Intelligence*.

2. Repositori de Codi i Automatització ETL (Scripts Python) S'ha creat un directori de codi font que conté els diferents scripts desenvolupats en Python (Pandas, NumPy, ydata-profiling). Aquest codi no és d'un sol ús, sinó que s'ha dissenyat de manera modular per garantir la **reproductibilitat** del procés. Actua com a motor d'integració que permetrà automatitzar la ingesta i transformació de futures enquestes que la fundació OSMI pugui publicar en els pròxims anys, integrant-les al model sense necessitat d'intervenció manual.

3. Diccionari de Dades i Mapeig Semàntic S'ha elaborat un document tècnic (disponible als Annexos d'aquesta memòria) que recull totes les regles de transformació i la lògica de negoci aplicades. Aquest diccionari certifica com s'ha resolt l'*Schema Drift*, justificant detalladament com la dispersió de les 214 preguntes originals dels formularis històrics s'ha mapejat cap a l'estructura final. És un document essencial per a la governança de dades (*Data Governance*) del projecte.

4. Arquitectura Dimensional Lògica Tot i que la implementació física i visual es durà a terme en la següent fase del projecte, el **disseny de l'Esquema en Estrella** validat a l'apartat 2.6 es considera un producte arquitectònic en si mateix. L'especificació clara de la Taula de Fets i les cinc Taules de Dimensions garanteix que el pas de les dades cap al motor analític VertiPac de Power BI es farà de forma òptima i sense errors d'integritat referencial.

5. Memòria Tècnica i Metodològica El present document acadèmic actua com a producte informatiu de tot el procés estratègic. La memòria no només reflecteix les línies de codi, sinó que documenta la investigació de la literatura (mitjançant PRISMA), justifica la selecció de les metodologies estructurals (Kimball i HEFESTO) i recull la formulació matemàtica dels KPIs que donaran resposta a les necessitats corporatives.

Aquests productes actuen com a requisit previ indispensable i marquen el final de la fase de preparació (*Data Preparation*). Estan completament a punt per ser utilitzats a les següents etapes del Treball Final de Grau: la construcció del Quadre de Comandament i l'entrenament dels models de *Machine Learning*.

2.8. Justificació de l'eina de visualització i explotació: Power BI

L'elecció de Microsoft Power BI com a eina final per a la capa de presentació i explotació analítica no respon únicament a la seva posició de lideratge al Quadrant Màgic de Gartner per a plataformes d'Analytics i BI, sinó a tres criteris tècnics fonamentals alineats amb l'arquitectura del projecte:

- **Sinergia nativa amb el modelatge dimensional:** L'esquema en estrella (*Star Schema*) desenvolupat a PostgreSQL és l'estructura de dades òptima per al motor VertiPaq de Power BI. Aquest motor d'emmagatzematge columnar en memòria comprimeix les dades i ofereix temps de resposta immediats en el filtratge creuat entre dimensions (com filtrar empleats per departament, any i gènere simultàniament).
- **Potència del llenguatge DAX:** La definició de KPIs complexos, com el "Risc de Fuga de Talent" (que requereix avaluar condicions simultànies de rendiment alt i factors culturals negatius), només és possible mitjançant expressions avançades com DAX (*Data Analysis Expressions*). DAX permet la creació de mesures dinàmiques que s'avaluen en temps d'execució segons el context de filtre de l'usuari. El càlcul d'aquest Risc de Fuga s'ha programat mitjançant DAX, recolzant-se en les metodologies d'avaluació de context descrites per **Russo i Ferrari (2015)**.
- **Adopció per part de l'usuari final (HR):** Atès que els usuaris finals d'aquest quadre de comandament són perfils directius i tècnics de Recursos Humans (no necessàriament especialistes en enginyeria de dades), Power BI ofereix una interfície interactiva de *Business*

Intelligence d'autoservei (Self-Service BI), facilitant la presa de decisions intuïtiva sense requerir coneixements d'SQL.

2.9. Reflexions sobre l'arquitectura i la gestió de la incrementalitat.

Davant del repte de gestionar un històric de dades d'enquestes anuals, es va descartar la implementació d'un *Enterprise Data Warehouse* tradicional, pesat i monolític. En el seu lloc, s'ha optat per una arquitectura modular i lleugera: un *pipeline* ETL programat íntegrament en Python que actua com a pont cap a una base de dades *serverless* a Neon (PostgreSQL).

Aquesta arquitectura desacoplada s'ha dissenyat pensant específicament en la incrementalitat de les càrregues:

- **Gestió de nous fitxers:** Atès que l'OSMI allibera una nova enquesta cada any, el sistema està preparat per a l'escalabilitat. Quan es publiqui l'arxiu `osmi_survey_2024.csv`, l'usuari només haurà de dipositar-lo al directori de dades brutes. El mòdul d'extracció de l'script `02_etl.py` iterarà automàticament sobre el nou fitxer sense trencar les dades existents.
- **Idempotència i prevenció de duplicats:** La incrementalitat es garanteix a la capa de base de dades mitjançant restriccions d'integritat. A la dimensió de temps, s'ha definit la restricció `UNIQUE` per a l'any de l'enquesta combinada amb la clàusula `ON CONFLICT DO NOTHING` a l'script de càrrega. Això permet executar l'ETL múltiples vegades sense risc d'inserir dimensions duplicades.

Aquest enfocament demostra que per a processos de *batch processing* anual (com són les enquestes de clima laboral), una infraestructura programàtica en Python i SQL és més àgil, eficient i menys costosa de mantenir que solucions de *Change Data Capture (CDC)* pròpies de sistemes transaccionals en temps real.

2.10. Justificació del modelatge de dades sintètiques i avaluació del seu impacte.

Un dels reptes més significatius a l'hora d'aplicar intel·ligència de negoci a problemàtiques de salut mental és la manca de dades financeres en els estudis clínics oberts. El *dataset* de l'OSMI ofereix una visió exhaustiva de l'estat psicològic dels treballadors, però no disposa de les variables organitzatives

(salari, hores extres, nota de rendiment) necessàries per avaluar el Retorn de la Inversió (ROI) o l'impacte operatiu.

Justificació metodològica: Per superar aquesta limitació i transformar l'estudi en una autèntica eina de *HR Analytics*, es va decidir hibridar les dades reals amb dades corporatives sintètiques (*Mock Data*). Aquesta hibridació de dades s'alinea amb els principis del **Predictive HR Analytics (Edwards & Edwards, 2019)**. Aquesta generació no es va realitzar de manera completament aleatòria, sinó que es va basar en la simulació probabilística de l'entorn laboral mitjançant la llibreria *NumPy*:

- La càrrega de treball (*Hores Extres*) es va simular mitjançant una **Distribució de Poisson**, atès que reflecteix l'asimetria real de les empreses (molts empleats no fan hores extres, mentre que uns pocs pateixen sobrecàrrega severa).
- Els costos (*Salari Anual*) es van projectar amb una **Distribució Normal** representativa dels barems del sector tecnològic.

Valoració de l'impacte: L'impacte d'aquesta decisió en la qualitat del Treball Final de Grau ha estat absolutament transformador. La generació d'aquestes dades ha permès:

- Calcular indicadors clau de negoci altament complexos, com el **Cost de Pèrdua de Productivitat (CPP)**, passant d'una anàlisi qualitativa ("hi ha gent estressada") a una quantitativa ("l'estrès té un cost estructural estimat de 17M €").
- Entrenar un model d'Intel·ligència Artificial en la **Prova de Concepte (PoC)** que correlaciona de manera proactiva l'excés d'hores extres amb el *burnout*. Tot i que les xifres financeres són simulades, l'arquitectura matemàtica, l'ETL i el codi DAX són completament funcionals. Aquesta decisió de disseny garanteix que el producte final sigui escalable i directament aplicable al mercat real: una empresa tecnològica només hauria de substituir l'arxiu de simulació de Python pels seus registres reals del departament de Nòmines i Control Horari perquè el quadre de comandament i els models predictius funcionessin amb dades corporatives verídiques.

3. Resultats

Aquest capítol presenta de manera sistemàtica, analítica i ordenada tots els productes tangibles i els resultats quantitatius obtinguts durant la fase d'implementació del projecte. Els resultats s'organitzen seguint el flux natural del pipeline d'enginyeria de dades: des de la ingesta i neteja de les fonts primàries, passant per la construcció i validació del Data Warehouse, fins a l'explotació analítica avançada mitjançant el quadre de comandament i els models d'Aprenentatge Automàtic (Machine Learning). Aquests resultats certifiquen la viabilitat tècnica de l'arquitectura dissenyada per a l'avaluació del benestar corporatiu.

3.1. Pipeline ETL i Dataset Consolidat

El primer gran repte d'aquest TFG consistia a extreure valor d'unes dades altament desestructurades. El pipeline ETL ha demostrat ser robust i eficaç en cadascuna de les seves fases.

3.1.1. Execució del procés d'Extracció (Extract)

S'han ingerit amb èxit els nou fitxers CSV corresponents a l'històric d'enquestes de l'OSMI (2014-2023). La concatenació vertical bruta d'aquests arxius, executada mitjançant la funció `pd.concat` de la llibreria Pandas, ha generat una matriu inicial de 4.701 registres. Aquesta matriu es va expandir fins a les 214 columnes totals, confirmant empíricament la greu problemàtica de la Deriva d'Esquema (Schema Drift) que ja s'havia diagnosticat durant la fase de Data Profiling.

3.1.2. Resolució de l'Schema Drift (Transform)

La fase de transformació ha constituït el nucli algorísmic del pipeline. La implementació d'un diccionari de mapeig semàntic en Python ha permès comprimir i unificar les 214 columnes originals en 12 variables clíniques i demogràfiques altament estandarditzades. Aquesta fase ha assolit les fites de qualitat de dades següents:

- **Normalització de gènere:** Les més de 40 entrades de text lliure introduïdes subjectivament pels usuaris (ex: "male", "m", "cis male") s'han agregat amb èxit en tres categories estandarditzades mitjançant l'ús d'expressions regulars (Regex).

- **Filtratge d'edats invàlides:** S'han auditat i purgat els registres amb edats fora del rang lògic de població activa (18 a 75 anys), eliminant el soroll derivat d'errors tipogràfics manuals dels usuaris.
- **Imputació estratègica de valors nuls:** Per tal de preservar el màxim volum d'informació per als models predictius posteriors, els valors buits en variables categòriques s'han imputat sota l'etiqueta neutral "No respon/Desconegut".

3.1.3. Enriquiment amb dades sintètiques (Mock Data)

Per dotar el projecte d'una autèntica utilitat en l'àmbit dels Recursos Humans, s'ha executat un mòdul d'enriquiment per pal·liar la naturalesa exclusivament clínica de l'OSMI. L'ús de la llavor aleatòria `np.random.seed(42)` garanteix la reproductibilitat científica de l'estudi. S'han injectat les mètriques següents:

- **Salari anual:** Simulat mitjançant una distribució Normal $N(\mu=65.000, \sigma=15.000)$, acotada entre 25.000 € i 150.000 €, per representar fidelment l'espectre retributiu del mercat tecnològic europeu.
- **Hores extres setmanals:** Generades mitjançant una distribució de Poisson $P(\lambda=3)$. Aquesta elecció matemàtica modela amb precisió l'asimetria del món laboral real: una gran majoria d'empleats realitzant poques hores extres i una minoria patint una càrrega severa.
- **Departament i Rendiment:** Assignació ponderada entre sis àrees tecnològiques (amb predominança de Backend amb un 30%) i una nota d'avaluació de l'acompliment (1-5) esbiaixada positivament per reflectir una plantilla generalment competent.

3.1.4. Fase de Càrrega (Load) i Arxiu Mestre

La culminació del procés ETL ha donat com a fruit l'arxiu mestre `osmi_unificat_NET_SINTETIC.csv`, establint la font de veritat única (Single Source of Truth) de tota l'arquitectura. Aquest actiu de dades compta amb 4.701 treballadors únics i només 17 columnes netes. Això suposa una reducció dimensional del 92% respecte al conjunt original, eliminant alhora el 90% dels valors nuls estructurals i garantint un rendiment òptim per a les etapes analítiques posteriors.

3.2. Arquitectura de Programari i Desenvolupament d'Scripts (Python)

Per garantir la reproductibilitat, l'escalabilitat i l'automatització del projecte, tota la lògica d'extracció, neteja, càrrega i modelatge predictiu s'ha encapsulat en un ecosistema d'scripts programats en llenguatge Python. Aquesta arquitectura es divideix en cinc mòduls executables principals que s'han dissenyat de forma seqüencial. La Taula X resumeix el rol de cadascun:

Mòdul	Funció principal	Tecnologies
00_data_profiling.py	Anàlisi Exploratòria i perfilat de dades (EDA)	pandas, ydata-profiling
01_Crea_Database.py	Definició DDL de l'Esquema en Estrella a Neon	sqlalchemy, psycopg2
02_etl.py	Motor ETL: Extract → Transform → Enrich → Load	pandas, numpy, sqlalchemy
03_MachineLearning.py	Model Random Forest sobre dades reals OSMI	scikit-learn, pandas
04_PoC_MachineLearning.py	Prova de Concepte amb correlació forçada (PoC)	scikit-learn, numpy

Figura 3. Ecosistema de scripts Python del projecte

A continuació, es detalla la funció de cadascun d'aquests scripts, fent especial èmfasi en el mòdul d'integració central (02_etl.py).

3.2.1. Mòdul 1: 00_data_profiling.py (Anàlisi Exploratòria i Perfilat de Dades)

Aquest script inicial és l'encarregat d'executar l'Anàlisi Exploratòria de Dades (EDA) automatitzada sobre les fonts primàries.

Fa ús de la llibreria ydata-profiling per llegir els arxius CSV originals en brut. Durant el desenvolupament, es va detectar que l'alta fragmentació i la presència de dades corruptes als textos lliures provocaven fallades de memòria (memory leaks) en la generació de l'informe.

Per solucionar-ho, l'script s'ha optimitzat instanciant la funció ProfileReport amb el paràmetre minimal=True. Això redueix la càrrega computacional de càlculs complexos i aconseguir generat amb èxit l'informe d'auditoria interactiu en format HTML (OSMI_Report_Global.html). Aquest arxiu va ser la peça clau per diagnosticar el greu problema d'Schema Drift que va motivar el disseny de l'ETL.

OSMI Data Profiling Report (Global 2014-2023)

Overview

Overview Alerts 269 Reproduction	
Dataset statistics	
Number of variables	214
Number of observations	4701
Missing cells	781300
Missing cells (%)	77.7%
Total size in memory	7.7 MiB
Average record size in memory	1.7 KiB
Variable types	
Text	159
Numeric	19
Unsupported	21
Boolean	15

Figura 4. Resum exemple del OSMI_Report_Global.html

3.2.2. Mòdul 2: 01_Crea_Database.py (Definició de l'Esquema i Configuració del Data Warehouse)

Aquest script és l'encarregat de preparar la infraestructura física de la base de dades abans de rebre cap informació.

Fa ús de la llibreria sqlalchemy per connectar-se al servidor remot de Neon (PostgreSQL). El codi executa sentències DDL (Data Definition Language) que s'encarreguen, en primer lloc, d'esborrar estructures prèvies (mitjançant instruccions DROP TABLE IF EXISTS ... CASCADE), i posteriorment creen l'Esquema en Estrella dissenyat.

Genera de forma automatitzada les cinc taules de dimensions (amb les seves claus primàries SERIAL PRIMARY KEY) i la taula central fets_rendiment_benestar (amb les respectives restriccions de clau forana o REFERENCES).

3.2.3. Mòdul 3: 02_etl.py (El Motor d'Integració i Resolució de l'Schema Drift)

L'script 02_etl.py constitueix el motor principal del procés d'enginyeria de dades. El codi està dissenyat seguint un paradigma funcional i modular, dividint el pipeline en quatre fases ben diferenciades: Extracció, Transformació, Enriquiment i Càrrega. Aquest disseny permet una execució aïllada i seqüencial, facilitant-ne la depuració i l'escalabilitat futura.

FASE 1 - Extracció (extract)

La funció `extract(csv_files)` és la porta d'entrada de les dades al sistema. El seu funcionament es basa en la lectura iterativa del directori local on s'allotgen els arxius de les enquestes originals de l'OSMI. A nivell algorísmic, la funció llegeix cada fitxer .csv utilitzant la llibreria Pandas (`pd.read_csv`), però abans de processar-lo, hi injecta automàticament una nova columna anomenada `_any_enquesta` a partir del nom de l'arxiu. Això és fonamental per mantenir la traçabilitat temporal de cada resposta un cop totes les dades es barregin. Finalment, els DataFrames individuals s'agrupen en una única llista en memòria i s'uneixen mitjançant una concatenació vertical (`pd.concat`), generant la matriu bruta (raw data) inicial.

FASE 2 - Transformació i Neteja (transform)

Aquesta fase representa el major repte computacional del projecte a causa del fenomen conegut com a Schema Drift. S'ha estructurat en les accions següents:

- **Resolució de l'Schema Drift (`resolve_schema_drift`):** En comptes d'intentar unir manualment 214 columnes, s'ha implementat un algorisme de Cerca Intel·ligent ("Smart Match"). L'script utilitza un diccionari predefinit (`COLUMN_MAPPING`) que conté les paraules clau per a cada variable desitjada. A través de bucles niats, l'algorisme neteja cada columna del DataFrame original i comprova si la paraula clau hi està continguda.
- **Normalització de dades demogràfiques:** Les dades de text lliure són processades mitjançant funcions específiques. Per exemple, `normalitzar_genere` utilitza expressions regulars (`re.search`) per buscar patrons en les més de 40 respostes i agrupar-les en "Masculí", "Femení" o "Altres". Alhora, `normalitzar_edat` filtra el soroll estadístic eliminant edats fora del rang [18, 75].

- **Inversió Lògica Condicional:** Atès que l'enquesta canvia el sentit de la pregunta sobre represàlies a partir de l'any 2017, la fase transform aplica una màscara booleana que inverteix autònomament les respostes (substituint 'Yes' per 'No' i viceversa) només per als registres d'aquells anys, garantint la coherència matemàtica de la mètrica.
- **Imputació de valors nuls:** Tota la matriu resultant passa per un procés de neteja on els valors buits en variables categòriques són reemplaçats amb el mètode `.fillna("No respon/Desconegut")`, blindant el sistema contra pèrdues de dades durant l'entrenament.

FASE 3 - Enriquiment Corporatiu (enriquir)

Per dotar la matriu clínica d'una utilitat enfocada als Recursos Humans, l'script utilitza el mòdul `numpy.random` per injectar dades sintètiques (Mock Data). La instrucció inicial `np.random.seed(42)` actua com a àncora, assegurant la reproductibilitat científica. Les variables s'assignen mitjançant funcions de distribució matemàtica: el salari anual s'extreu d'una campana de Gauss (`np.random.normal`) limitada amb `.clip()`; les hores extres es generen via una distribució asimètrica (`np.random.poisson` amb $\lambda=3$); i el departament i el rendiment s'afegeixen mitjançant `np.random.choice()` amb un vector de probabilitats ponderades.

FASE 4 - Càrrega i Modelatge Dimensional (load)

El darrer tram del pipeline materialitza el Data Warehouse. La funció `load(df)` estableix una connexió via SQLAlchemy amb el servidor PostgreSQL a Neon. El procés d'inserció s'ha programat meticulosament en tres passos:

- **Inserció de Dimensions:** L'algorisme extreu les combinacions úniques per a cada taula de dimensió (`df[cols].drop_duplicates()`) i utilitza la clàusula `RETURNING id_...` de PostgreSQL per capturar l'identificador únic generat, emmagatzemant-lo en un diccionari en memòria RAM.
- **Mapeig de la Taula de Fets:** Aprofitant els diccionaris generats, s'assigna el Foreign Key corresponent a cada empleat i s'executa un bolcat massiu (`INSERT INTO fets_rendiment_benestar`) que insereix els 4.701 registres vinculats perfectament amb les seves dimensions.
- **Exportació Màster:** El mètode `exportar_csv` grava tota la matriu processada en el fitxer físic `osmi_unificat_NET_SINTETIC.csv`, que s'utilitza com a font àgil per alimentar i entrenar posteriorment els algorismes de Machine Learning.

3.2.4. Mòdul 4: 03_MachineLearning.py (Model Clínic i RRHH)

Aquest script està dissenyat per executar l'entrenament dels models d'Aprenentatge Automàtic supervisat sobre les dades resultants de l'ETL. Incorpora la llibreria Scikit-Learn i s'encarrega d'importar l'arxiu mestre unificat. A nivell de processament, executa la transformació de variables de text a matrius numèriques binàries mitjançant la tècnica de One-Hot Encoding (`pd.get_dummies`), configura i entrena l'algorisme Random Forest Classifier (limitat a una profunditat màxima de 10 nivells per evitar el sobreajustament) i programa l'extracció de la mètrica `feature_importances_` per llistar els factors estructurals que prediuen l'estrès dels treballadors.

3.2.5. Mòdul 5: 04_PoC_MachineLearning.py (Prova de Concepte)

Un script complementari dissenyat com a demostrador tecnològic (Prova de Concepte). S'hi programa expressament la injecció de regles de negoci mitjançant condicions matemàtiques (`np.where`), forçant una correlació directa entre treballadors que pateixen estrès i alts volums d'hores extres combinats amb baix rendiment. Aquest script prova l'eficàcia de l'arquitectura dissenyada per auditar i capturar relacions operatives amb precisions superiors al 99%, demostrant que el sistema està completament preparat per rebre dades de control horari d'un entorn corporatiu real.

3.3. Data Warehouse a Neon PostgreSQL

El disseny conceptual s'ha materialitzat físicament mitjançant la càrrega del dataset consolidat a un Data Warehouse allotjat al núvol sota l'arquitectura de Neon (PostgreSQL serverless). S'ha aplicat rigorosament la metodologia dimensional de Ralph Kimball per establir un Esquema en Estrella. L'ordre d'inserció s'ha programat meticulosament (creant les dimensions prèviament als fets) per assegurar la integritat referencial absoluta.

L'arquitectura relacional resultant al servidor consta de sis taules:

- **dim_temps:** 9 registres històrics anuals (2014-2023), incloent-hi flags contextuais com "Pre-COVID" i "Post-COVID".

- **dim_demografia:** Combinacions úniques de variables com la franja d'edat, el gènere i el país de residència.
- **dim_entorn_laboral:** Vectors únics que descriuen el context operatiu (departament, mida d'empresa, teletreball i rol tècnic).
- **dim_salut_mental i dim_cultura_empresa:** Taules que encapsulen l'estat clínic reportat i la percepció de les polítiques corporatives de suport.
- **fets_rendiment_benestar (Taula Central):** Matriu quantitativa composta per 4.701 registres que enllacen, a través de claus foranes, amb les dimensions descrites, albergant les mètriques sumables (salari, hores extres, rendiment).

3.4. Model de Machine Learning (03_MachineLearning.py)

Per cobrir el component d'analítica predictiva (OS5), s'ha procedit a l'entrenament d'un model d'aprenentatge automàtic supervisat per classificar la necessitat de tractament terapèutic d'un empleat (utilitzat com a proxy quantificable del burnout, tal com valida la literatura científica de referència: Reddy, 2018; Katarya, 2022; Memon, 2023).

3.4.1. Configuració i rendiment del model

L'algoritme seleccionat ha estat el Random Forest Classifier de Scikit-Learn, configurat amb 100 arbres i una profunditat màxima de 10 nivells per evitar el sobreajustament (overfitting). L'entrenament s'ha realitzat exclusivament sobre 2.720 registres amb dades reals confirmades de l'OSMI, separant un 20% (544 registres) per a la fase de validació (Test).

```

Algoritme:          Random Forest Classifier
n_estimators:       100 arbres de decisió
max_depth:          10 nivells màxims per arbre
random_state:       42 (reproductibilitat garantida)
Train/Test split:   80% / 20% → 2.176 train / 544 test
Variables entrada:  36 (after One-Hot Encoding)
Variable objectiu:  te_tractament (0 = No, 1 = Sí)

```

Els resultats sobre dades no vistes presenten un Accuracy global del 75,00%. La *Figura 5* resumeix les mètriques d'avaluació completes:

Classe	Precision	Recall	F1-Score	Support
0 – No necessita tractament	0.66	0.63	0.65	197 treballadors
1 – Necessita tractament	0.80	0.82	0.81	347 treballadors
Accuracy global	—	—	75.00%	544 treballadors
Macro avg	0.73	0.72	0.73	544 treballadors
Weighted avg	0.75	0.75	0.75	544 treballadors

Figura 5. Classification Report – Model Random Forest (dades reals OSMI)

Aquest rendiment és altament competitiu en l'àmbit de la psicometria i els recursos humans. Destaca substancialment la capacitat del sistema per identificar casos positius (Classe 1), assolint un Recall del 82%. Això demostra que el model minimitza efectivament els falsos negatius (capturant 4 de cada 5 empleats que realment requereixen ajuda clínica), el paràmetre més crític a l'hora d'implementar polítiques de prevenció en riscos laborals.

3.4.2. Anàlisi d'Importància de Variables (Feature Importance)

Més enllà de la predicció aïllada, el valor analític de l'algorisme rau en comprendre l'estructura causal subjacent mitjançant la mètrica d'importància de Gini. La Figura 6 mostra el rànquing complet de les deu variables més determinants:

Rang	Variable	Importància
1	anonimat_Yes (Percepció d'anonimat positiva)	0.2200 (22.0%)
2	anonimat_No (Absència d'anonimat)	0.1528 (15.3%)
3	edat_num (Edat numèrica de l'empleat)	0.1427 (14.3%)
4	facilitat_baixa_No respon/Desconegut	0.0534 (5.3%)
5	es_rol_tech_Yes (Rol tècnic confirmat)	0.0389 (3.9%)
6	teletreball_No (Sense teletreball)	0.0334 (3.3%)
7	es_rol_tech_1.0 (Variant rol tècnic)	0.0304 (3.0%)
8	genere_Masculí	0.0297 (3.0%)

Rang	Variable	Importància
9	por_represalies_No	0.0251 (2.5%)
10	genere_Femení	0.0231 (2.3%)

Figura 6. Top 10 variables predictores – Model Random Forest

Aquests resultats certifiquen de manera matemàtica que la garantia de confidencialitat és la pedra angular del benestar. Les variables relacionades amb l'anonimat lideren l'espectre predictiu acumulant un 37,3% d'importància total. L'algorisme conclou empíricament que la percepció de privacitat i l'edat de l'empleat (14,3%) són indicadors immensament més sòlids per predir la necessitat de teràpia que factors tradicionalment debatuts com el teletreball o el gènere.

3.5. Prova de Concepte (PoC) en Predictive HR Analytics

Per demostrar la completa adaptabilitat del codi desenvolupat a entorns purament corporatius, s'ha desenvolupat una Prova de Concepte (PoC) paral·lela. Atès que el dataset de l'OSMI no conté indicadors corporatius reals, s'ha dissenyat un escenari sandbox on s'han injectat correlacions forçades: una població amb burnout operatiu sota altes càrregues de treball $N(\mu=12, \sigma=3)$ i baix rendiment, versus una població sana amb jornades estables $N(\mu=2, \sigma=1)$ i rendiment òptim.

Classe	Precision	Recall	F1-Score	Support
0 – No burnout operatiu	0.98	0.99	0.99	197 treballadors
1 – Burnout operatiu	1.00	0.99	0.99	347 treballadors
Accuracy global	—	—	99.26%	544 treballadors

Figura 7. Classification Report – Prova de Concepte (PoC) amb variables sintètiques

Aquesta xifra de precisió del 99,26% no s'ha d'interpretar com un rendiment generalitzable en un entorn caòtic de producció. L'èxit d'aquest resultat és estrictament demostratiu: quantifica el potencial de millora si s'integren dades reals d'hores extres als sistemes BI. Les variables operatives (hores extres 64,9% i rendiment 26,3%) eclipsen completament les clíniques, demostrant que el pipeline de Machine Learning construït és perfectament capaç de desxifrar relacions ocultes si se l'alimenta amb dades reals dels programaris de gestió de l'empresa.

3.6. Quadre de Comandament (Power BI)

Finalment, la integració del magatzem de dades a Power BI ha permès materialitzar tot l'esforç d'enginyeria en una eina viva, interactiva i orientada a la presa de decisions corporatives. Aprofitant la idoneïtat de l'esquema en estrella per als motors OLAP (VertiPaq), l'ús avançat del llenguatge DAX ha permès transformar les dades crues en els KPIs estratègics definits anteriorment.

La Figura 8 resumeix les mètriques clau assolides sobre el conjunt total de la plantilla:

KPI	Valor obtingut	Descripció	Relació amb objectiu
Total treballadors	4.701	Registres nets carregats i auditats al Data Warehouse	OS3 – ETL completat
Massa Salarial total	306 milions	Agregació dels salaris sintètics generats per a tota la plantilla	OS2 – Dades sintètiques
Cost Pèrdua Productivitat (CPP)	17 milions	Estimació financera: Salari × Coeficient d'Interferència Clínica	OS1, OS4 – KPI principal
Taxa de tractament	37,35%	Proporció de la plantilla global que està rebent suport psicològic actiu.	Context clínic i base del model predictiu
Talent crític en risc	29,97%	Expressió relativa del RFTC: percentatge d'empleats d'alt valor (Rendiment ≥ 4) amb simptomatologia de fatiga o por a represàlies.	OS5 – Retenció de talent

Figura 8. Resum de KPIs del Quadre de Comandament Power BI

3.6.1. KPI's principals BI i cost de l'estrès

La pàgina principal que actua com un panell de control macro.

D'entrada, la **Taxa de tractament (37,35%)** estableix una línia base clínica innegable sobre l'estat de la plantilla. Des d'una perspectiva de negoci, l'anàlisi del CPP demostra que departaments sotmesos a una gran pressió tecnològica, com Backend i Frontend, lideren les pèrdues de productivitat (5,1 i 4,4 milions d'euros respectivament). Aquest fet s'alinea de manera coherent amb la seva forta representativitat en la mostra (30% i 25%) i la seva exposició històrica a factors d'estrès com entregues contínues o resolució d'incidències crítiques.




Figura 9. Pagina principal Quadre de Comandament Power BI

També podem veure l'indicador de **Talent crític en risc (29,97%)**. Aquesta mètrica amb percentatge ens fa veure que pràcticament un terç dels professionals imprescindibles operen sota fatiga laboral crònica. Això no és només una estadística; és un *insight* relatiu que dota Recursos Humans d'una alarma primerenca per intervenir abans que es produeixin rotacions de personal d'altíssim cost de reemplaçament. La pàgina es tanca amb l'evidència predictiva del Factor de Risc, que alerta la direcció que l'excés d'hores extres incrementa un 6% el risc de *burnout*, assenyalant directament a la cultura de la sobrecàrrega.

3.6.2. Anàlisi Demogràfica, Geogràfica i Biaixos

Aquí s'intenta aprofundir en la distribució del problema per entendre **a qui** li està afectant més. Així revisem la diversitat i la intervenció preventiva:

- **Anàlisi de Gènere (Gràfics de Tornat):** Els resultats revelen un biaix significatiu i constant. Les dones presenten un Cost de Productivitat Mig i un percentatge de fugues potencials superiors als homes en gairebé tots els departaments i mides d'empresa (arribant a un 47% de risc en organitzacions de 500-1000 empleats, respecte al 32% masculí), evidenciant una càrrega mental desigual.
- **Mapa i Edat (Punts calents):** L'encreuament geogràfic mundial i la matriu d'impacte (Edat vs. Departament) funcionen com un escàner d'alerta. Permeten localitzar "punts calents" de fatiga, com ara despeses de presentisme inusualment altes en determinades franges d'edat, guiant les intervencions psicosocials de manera totalment micro-segmentada.




Figura 10. Pàgina secundària Quadre de Comandament BI

Aquest quadre de comandament va més enllà de mostrar únicament què està passant dins de l'organització, ja que també ajuda a identificar en quines àrees es concentren els problemes i quins factors poden estar relacionats amb aquestes situacions. D'aquesta manera, la informació obtinguda es converteix en una eina útil per donar suport a la presa de decisions i per justificar la necessitat d'invertir en polítiques de salut mental i benestar laboral com a part de l'estratègia de sostenibilitat i retenció de talent de l'empresa.

3.7. Resum i valoració dels objectius assolits

El present projecte assoleix una avaluació altament satisfactòria quant a l'execució i compliment dels paràmetres establerts. L'arquitectura End-to-End dissenyada integralment, amb fluïdesa metodològica, les quatre capes fonamentals del Business Intelligence: la ingesta robusta de dades, l'emmagatzematge dimensional, l'anàlisi descriptiva i l'anàlisi predictiva.

La figura 11 documenta la traçabilitat directa entre els objectius definits inicialment i els actius analítics obtinguts:

ID	Objectiu secundari	Resultat aconseguit
OS1	Anàlisi i unificació de les fonts de dades OSMI (2014-2023)	Dataset de 4.701 registres auditats i compressió dimensional d'un 92% a variables netes.
OS2	Generació de dades sintètiques per a mètriques corporatives	Mock Data completament integrat i reproducible respectant lleis de distribució matemàtica.
OS3	Disseny i implementació del procés ETL mitjançant Python	Operativització de l'script 02_etl.py abastant la resolució autònoma del Schema Drift.
OS4	Modelatge del Data Warehouse segons l'enfocament de Kimball	Implementació serverless a Neon PostgreSQL basada en l'Esquema en Estrella amb sis taules relacionals.
OS5	Desenvolupament de l'algorisme predictiu (Machine Learning)	Model Random Forest validat al 75% i demostració pràctica (PoC) validada al 99%.
OS6	Implementació del Quadre de Comandament final en Power BI	Integració de dades presentant l'estimació de pèrdua productiva i filtratge avançat interactiu.

Figura 11. Traçabilitat entre objectius i l'obtingut

4. Conclusions i treballs futurs

Aquest treball ha estat molt més que un exercici de programació o d'arquitectura de dades; ha estat un camí per intentar posar llum a una realitat sovint invisible en el nostre sector: el desgast emocional dels professionals que construïm la tecnologia. A través de la combinació de dades clíniques reals i variables corporatives, hem aconseguit transformar "sensacions" en evidències que no es poden ignorar.

Des d'una perspectiva **personal i metodològica**, les lliçons d'aquest viatge han estat reveladores:

- **De la complexitat a la claredat:** He pogut comprovar com, mitjançant la tecnologia (Python i el procés ETL), podem posar ordre al caos de dades fragmentades. El fet de reduir més de 200 preguntes disperses a 17 indicadors clars no és només un èxit tècnic, sinó una manera de fer que la veu dels treballadors sigui realment entesa per les organitzacions.
- **La dada com a eina d'empatia:** L'ús de dades sintètiques no ha estat només una solució a la falta d'informació financera, sinó un pont per unir dos mons que sovint no es parlen: el benestar i el compte de resultats. He volgut demostrar que cuidar de les persones no és només una qüestió ètica, sinó el motor de la sostenibilitat de qualsevol empresa.

Pel que fa als **resultats i l'impacte humà** del *Dashboard*, les conclusions ens conviden a la reflexió:

- **El preu del silenci:** Hem quantificat que el "no estar bé" té un cost. Aquests **17 milions d'euros** en pèrdua de productivitat (CPP) són el reflex econòmic d'hores de patiment i falta d'energia en equips crítics com Backend o Frontend. La dada ens diu que la salut mental és una inversió, no una despesa.
- **L'anonimat com a refugi:** Una de les troballes més potents de l'algorisme de *Machine Learning* és que, per damunt del salari o el teletreball, el que realment fa que un empleat busqui ajuda és sentir-se segur i protegit. Si no hi ha confiança i anonimat, qualsevol política de benestar serà només "maquillatge" corporatiu.
- **Un crit d'alerta per al talent:** Saber que gairebé un **30% del nostre millor talent** opera sota una fatiga severa és una alarma que cap líder pot obviar. Aquest TFG ens permet posar noms i cognoms (o almenys departaments) a aquest risc, actuant abans que el professional decideixi marxar.
- **La cultura de la sobrecàrrega:** Hem demostrat matemàticament que el desgast no és fruit de la casualitat. El factor de risc de **1,06x** vinculat a les hores extres és una evidència directa que el nostre model de treball actual necessita una revisió profunda per evitar el *burnout* de la plantilla.

4.1. Treballs futurs

Aquest projecte no neix amb la intenció de ser una foto estàtica, sinó com la llavor d'un ecosistema que ha de continuar creixent per cuidar millor de les persones. Per portar aquesta eina al següent nivell i fer-la encara més útil per al dia a dia de les organitzacions, s'apunten les següents línies de treball:

- **Cap a una predicció més precisa i preventiva:** No ens volem quedar només en el que ha passat. L'objectiu és aprofundir en **Models Avançats d'Aprenentatge Automàtic**, optimitzant els hiperparàmetres i testant algorismes més potents com XGBoost. Això ens permetrà millorar l'anticipació del risc de baixa laboral, actuant abans que el malestar esdevingui un problema de salut greu per al treballador.
- **Una eina que bategui en temps real:** Perquè les decisions siguin realment efectives, les dades han d'estar vives. Es proposa la **Integració de Fonts de Dades en Temps Real (Streaming Data)**, connectant el nostre magatzem de dades directament amb sistemes de gestió de Recursos Humans com Workday o BambooHR mitjançant APIs. D'aquesta manera, els KPIs no seran un resum del passat, sinó un reflex dinàmic del present de la plantilla.
- **Entendre la veu dels empleats:** Darrere de cada xifra hi ha una història que moltes vegades s'explica amb paraules. Volem incorporar el **Processament de Llenguatge Natural (NLP)** per realitzar anàlisis de sentiment sobre els textos lliures de les enquestes. Això ens permetrà extreure el valor emocional que s'amaga en les respostes desestructurades, entenent millor les preocupacions reals de l'equip.
- **Intel·ligència Artificial al servei de l'empatia:** Finalment, volem aprofitar el potencial de la **IA Generativa (LLMs)** per construir un "Copilot" integrat a Power BI. La idea és que qualsevol mànager pugui formular preguntes en llenguatge natural i rebre respostes visuals i *insights* de valor a l'instant, facilitant una gestió més humana, ràpida i basada en la comprensió profunda de les necessitats de la seva gent.

5. Glossari

Intel·ligència Artificial (IA):

És el camp de la informàtica dedicat a crear sistemes i programes capaços de realitzar tasques que normalment requereixen intel·ligència humana, com aprendre, raonar, resoldre problemes o reconèixer patrons.

Business Intelligence (BI): Conjunt d'estratègies, processos, aplicacions i tecnologies orientades a la recopilació, integració i anàlisi de dades per facilitar la presa de decisions corporatives.

Data Warehouse (Magatzem de dades): Sistema centralitzat d'emmagatzematge de dades integrades procedents de múltiples fonts, dissenyat específicament per a la consulta i l'anàlisi analítica.

Deriva d'Esquema (Schema Drift): Fenomen pel qual l'estructura, els camps o els tipus de dades d'una font d'informació canvien de manera imprevisible al llarg del temps, requerint adaptacions en els sistemes d'integració.

Esquema en Estrella (Star Schema): Model de disseny de bases de dades dimensionals on una taula central (Taula de Fets) està envoltada per diverses taules perifèriques (Taules de Dimensions) formant una estrella.

ETL (Extract, Transform, Load): Procés fonamental en la integració de dades que consisteix a extreure informació de les fonts, transformar-la per netejar-la i estructurar-la, i carregar-la al sistema de destinació.

Mock Data (Dades Sintètiques): Dades generades artificialment mitjançant algorismes que imiten les propietats estadístiques de les dades reals, utilitzades per enriquir models, fer proves o protegir la privacitat.

Taula de Fets i Taula de Dimensions: En modelatge dimensional, la Taula de Fets conté les mètriques quantitatives i mesurables del negoci, mentre que les Taules de Dimensions contenen els atributs descriptius que donen context a aquests fets.

Python: Llenguatge de programació àmpliament utilitzat en ciència de dades, aprenentatge automàtic i intel·ligència artificial per la seva senzillesa i potent ecosistema de biblioteques.

Data Profiling (Perfilat de Dades): Procés d'anàlisi exploratòria inicial d'un conjunt de dades per comprendre'n l'estructura, identificar anomalies, valors nuls i avaluar-ne la qualitat abans d'iniciar el procés de transformació.

Single Source of Truth (SSOT / Font de Veritat Única): Principi d'arquitectura de dades on la informació es normalitza i emmagatzema en un únic lloc centralitzat (en aquest projecte, l'arxiu mestre unificat), garantint que tots els sistemes de l'empresa utilitzin exactament les mateixes dades fiables.

Script: Arxiu de text que conté un conjunt d'instruccions escrites en un llenguatge de programació (com Python) que s'executen de manera seqüencial per automatitzar una tasca (ex: l'extracció i neteja de dades).

DAX (Data Analysis Expressions): Llenguatge de fórmules utilitzat a Power BI per crear càlculs analítics avançats, mesures personalitzades i consultes sobre un model de dades relacional.

KPI (Key Performance Indicator / Indicador Clau de Rendiment): Mètrica quantificable que s'utilitza per avaluar l'èxit d'una organització o d'una activitat concreta (com el Cost de Pèrdua de Productivitat) respecte als seus objectius estratègics.

Dashboard (Quadre de Comandament): Interfície gràfica d'usuari que consolida i visualitza els KPIs i mètriques més rellevants d'un projecte en una sola pantalla, permetent la monitorització i la presa de decisions ràpida.

Machine Learning (Aprenentatge Automàtic): Branca de la intel·ligència artificial que utilitza algorismes i models estadístics per permetre que els ordinadors aprenguin patrons a partir de les dades sense ser programats explícitament per fer-ho.

Random Forest (Bosc Aleatori): Algorisme d'aprenentatge automàtic supervisat que crea múltiples arbres de decisió durant l'entrenament i n'extreu la

moda de les classes (per a classificació) com a predicció final, destacant per la seva alta precisió i resistència al sobreajustament.

Accuracy (Acuradesa / Precisió Global): Mètrica d'avaluació en models de classificació que representa el percentatge de prediccions correctes (tant positius com negatius vertaders) respecte al total de casos avaluats.

Recall (Sensibilitat / Taxa de Veritables Positius): Mètrica crítica en analítica predictiva que mesura la proporció de casos positius reals que el model ha estat capaç d'identificar correctament (ex: quants treballadors amb burnout real ha detectat el sistema).

Burnout (Síndrome del treballador cremat): Estat d'esgotament físic, emocional i mental vinculat a l'àmbit laboral, causat per l'exposició crònica a situacions d'estrès.

PoC (Prova de Concepte / Proof of Concept): Exercici pràctic amb un abast limitat i controlat (com la simulació realitzada en aquest projecte) que té per objectiu demostrar que una teoria, tecnologia o mètode és viable en un entorn real.

VertiPaq: Motor d'emmagatzematge en memòria (In-Memory) i columnar utilitzat per Microsoft a Power BI, capaç de comprimir enormes volums de dades i realitzar agregacions gairebé a l'instant, dissenyat especialment per a esquemes dimensionals.

Outliers (Valors atípics): Observacions o dades numèriques que presenten una desviació extrema respecte a la resta de la mostra, sovint causades per errors de mesura o d'introducció (com edats superiors a 100 anys).

One-Hot Encoding: Tècnica de preprocessament en Machine Learning que consisteix a convertir variables categòriques o de text (com departaments) en matrius de nombres binaris (0 i 1) perquè l'algorisme les pugui entendre matemàticament.

6. Bibliografia

Katarya, R., et al. (2022). "Mental Health Analysis of Employees using Machine Learning Techniques". *2022 International Conference on Computer Communication and Informatics (ICCCI)*. IEEE Xplore. DOI: 10.1109/ICCCI54379.2022.9668526.

Reddy, M. S., Thota, S., & Dharun, S. (2018). "Machine Learning techniques for stress prediction in IT professionals". *International Journal of Engineering & Technology*, 7(2.24), 227-230.

Page, M. J., McKenzie, J. E., Bossuyt, P. M., Boutron, I., Hoffmann, T. C., Mulrow, C. D., ... & Moher, D. (2021). "Declaración PRISMA 2020: una guía actualizada para la publicación de revisiones sistemáticas". *Revista Española de Cardiología*, 74(9), 790-799.

Memon, F. R. (2023). "Survey dataset on mental health in tech professionals from Open Sourcing Mental Health (OSMI) surveys (2017-2021)". *Mendeley Data*, V1. DOI: 10.17632/mmnzx4w8cg.1.

Open Sourcing Mental Illness (OSMI). (2014-2023). *Mental Health in Tech Survey*. Kaggle. Recuperat de: <https://www.kaggle.com/datasets/osmi/mental-health-in-tech-survey>

Bernabeu, R. D. (2010). *Data Warehousing: Investigación y Sistematización de Conceptos - Hefesto: Metodología propia para la Construcción de un Data Warehouse* (Versió 2.0). Còrdova, Argentina. Recuperat de: <https://www.dataprix.com/es/data-warehousing-metodologia-hefesto>

Kimball, R., & Ross, M. (2013). *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling* (3a ed.). John Wiley & Sons.

Harris, C. R., Millman, K. J., van der Walt, S. J., et al. (2020). "Array programming with NumPy". *Nature*, 585(7825), 357-362. DOI: 10.1038/s41586-020-2649-2.

McKinney, W. (2010). "Data Structures for Statistical Computing in Python". *A Proceedings of the 9th Python in Science Conference* (pp. 51-56).

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, E. (2011). "Scikit-learn: Machine Learning in Python". *Journal of Machine Learning Research*, 12, 2825-2830.

Russo, M., & Ferrari, A. (2015). *The Definitive Guide to DAX: Business intelligence with Microsoft Excel, SQL Server Analysis Services, and Power BI*. Microsoft Press.

Ferrari, A., & Russo, M. (2017). *Analyzing Data with Power BI and Power Pivot for Excel*. Microsoft Press.

World Health Organization (WHO). (2022). WHO guidelines on mental health at work. World Health Organization. Recuperat de: <https://www.who.int/publications/i/item/9789240053052>

Chisholm, D., Sweeny, K., Sheehan, P., Rasmussen, B., Smit, F., Cuijpers, P., & Saxena, S. (2016). Scaling-up treatment of depression and anxiety: a global return on investment analysis. *The Lancet Psychiatry*, 3(5), 415-424.

Edwards, M. R., & Edwards, K. (2019). *Predictive HR analytics: Mastering the HR metric* (2a ed.). Kogan Page Publishers.

Fitz-enz, J. (2010). *The new HR analytics: predicting the economic value of your company's human capital investments*. Amacom.

Brugman, S., et al. (2023). *ydata-profiling: Exploratory Data Analysis for Pandas and Spark DataFrames* (Versió 4.x) [Programari]. Recuperat de: <https://github.com/ydataai/ydata-profiling>

7. Annexos

Els annexos següents complementen la memòria principal i documenten els aspectes tècnics i metodològics del projecte, especialment els relacionats amb la governança de dades, el procés ETL, el model dimensional i el càlcul dels KPIs.

7.1. Diccionari de Dades i Mapeig Semàntic OSMI

Aquest annex documenta de manera exhaustiva les regles de governança de dades aplicades durant el procés ETL. Recull la correspondència entre les columnes originals de les enquestes OSMI (2014-2023) i les variables estandarditzades finals del Data Warehouse, incloent-hi les transformacions aplicades, la lògica de negoci i els coeficients utilitzats per al càlcul dels KPIs corporatius.

7.1.1. Anàlisi d'Importància de Variables (Feature Importance)

L'informe OSMI_Report_Global.html sobre el dataset brut (pre-ETL) ha revelat les problemàtiques estructurals que justifiquen el disseny del pipeline ETL:

Mètrica	Valor brut (pre-ETL)	Valor net (post-ETL)
Nombre de registres (files)	4.701	4.701 (0 eliminats)
Nombre de variables (columnes)	214	17 (reducció 92%)
Cel·les buides (NaN)	781.300 (77,7%)	<5% (imputació aplicada)
Variables de text (Text)	159	11 estandarditzades
Variables numèriques	19	6 (inclou 4 sintètiques)
Mida en memòria	7,7 MiB	<1 MiB
Alertes de qualitat detectades	268 (Schema Drift, NaN, outliers)	0 crítiques

Figura 12. Comparativa de qualitat de dades: pre-ETL vs. post-ETL

7.1.2. Evolució de l'Schema Drift per Any d'Enquesta

La derivació d'esquema (Schema Drift) és el problema estructural principal del dataset OSMI. La reformulació anual de les preguntes va generar 214 columnes en concatenar tots els CSV, amb el 77,7% de cel·les buides. La taula següent documenta les variants principals per any:

Any	Pregunta sobre diagnòstic (exemple)	Pregunta sobre interferència (exemple)	Pregunta sobre represàlies	Columnes totals
2014	Do you have a mental health condition?	If you have a mental health condition, do you feel that it interferes with your work?	mental_vs_physical (positiu→negatiu)	~27
2016	Do you currently have a mental health disorder?	(similar 2014)	Do you think discussing MH would have negative consequences?	~63
2017	Have you ever been diagnosed with a mental health disorder?	If you have a MH issue, do you feel it interferes... when NOT treated?	⚠ INVERSIÓ: Would you feel comfortable discussing MH with coworkers?	~100
2018-2019	Have you been diagnosed with a mental health condition by a medical professional?	If you have a MH issue... interferes when being treated / NOT treated?	(similar 2017 – invers)	~80-100
2020-2023	Do you *currently* have a mental health disorder? / Have you ever been *diagnosed*?	How often do you feel that it interferes with your work?	(similar 2017 – invers)	~80-120

Figura 13. Evolució de l'Schema Drift per variable i any (exemples representatius)

Nota: La fila 2017 marca el punt d'inflexió crític: la pregunta sobre represàlies canvia de sentit (de positiu a negatiu). L'ETL aplica una inversió lògica condicional (màscara booleana per any ≥ 2017) per garantir la coherència de la variable **por_represalies**.

7.1.3. Diccionari de dades i Mapeig semàntic complet

La taula següent constitueix el document de governança de dades del projecte.

Detalla per a cadascuna de les 17 variables estandarditzades: els noms originals de les columnes OSMI, els anys en què apareixien, la transformació aplicada i exemples de valors.

Les files amb fons blau clar corresponen a files de categories; les files de dades alternen en blanc i blau molt clar per facilitar-ne la lectura.

Variable estàndard	Any(s)	Nom(s) original(s) a l'OSMI	Transformació aplicada	Valors exemple
CATEGORIA 1 – Variables Demogràfiques				
edat	2014-2023	Age / What is your age? / age	Filtre outliers: [18, 75]. Conversió a int. Valors fora del rang → NaN i eliminació.	25, 34, 47
edat_franja	2014-2023	[generada a partir d'edat]	Agrupació en franges: 18-24 / 25-34 / 35-44 / 45-54 / 55+. Valors NaN → 'Desconegut'.	25-34, 45-54
genere	2014-2023	Gender / What is your gender? / gender	RegEx: patrons masculins → 'Masculí'. Patrons femenins → 'Femení'. Resta → 'Altres/No-Binari'. Valors NaN → 'No especificat'.	Male, m, cis male → Masculí
pais	2014-2023	Country / What country do you live in? / What country do you work in? / country	Selecció de la primera variant disponible per any. Valors NaN → 'No respon/Desconegut'.	United States, Spain
CATEGORIA 2 – Variables d'Entorn Laboral				
mida_empresa	2014-2023	no_employees / How many employees does your company or organization have? / How many employees does your employer have?	Selecció primera variant disponible. Valors NaN → 'No respon/Desconegut'.	26-100, More than 1000
teletreball	2014-2023	remote_work / Do you work remotely (outside of an office) at least 50% of the time? / Do you work remotely? /	Selecció primera variant disponible. Valors NaN → 'No respon/Desconegut'.	Yes, No, Sometimes

Variable estàndard	Any(s)	Nom(s) original(s) a l'OSMI	Transformació aplicada	Valors exemple
		Do you currently work remotely?		
es_rol_tech	2014-2023	tech_company / Is your employer primarily a tech company/organization? / Is your primary role within your company related to tech/IT?	Selecció primera variant disponible. Valors NaN → 'No respon/Desconegut'.	Yes, No, 1.0, 0.0
CATEGORIA 3 – Variables de Salut Mental (Clíniques)				
te_tractament	2014-2023	treatment / Have you sought treatment for a mental health condition? / Have you ever sought treatment for a mental health issue from a mental health professional? / Have you ever sought treatment for a mental health disorder from a mental health professional?	Variable target del model ML. Selecció primera variant. Filtratge a Yes/No per entrenament. Valors NaN → 'No respon/Desconegut'.	Yes, No
te_diagnostic	2014-2023	Do you have a mental health condition? (2014) / Do you currently have a mental health disorder? (2016-19) / Have you ever been diagnosed with a mental health disorder? (2017+) / Do you have a family history of mental illness? / Do you *currently* have a mental health disorder? (2021+)	Variable amb màxim Schema Drift (5 formulacions). Smart Match per keyword 'mental health condition/disorder'. Valor final = primera variant no nul·la per registre.	Yes, No, Maybe
interferencia_laboral	2014-2023	work_interfere / If you have a mental health condition, do you feel that it interferes with your work? / If you have a mental health issue, do you feel that it interferes with your work when NOT being	Mapeig semàntic per keyword 'interferes with your work'. Valors NaN → 'No respon/Desconegut'. KPI CPP deriva d'aquesta variable (Sovint=0.20, De vegades=0.10, Mai=0.0).	Often, Sometimes, Rarely, Never

Variable estàndard	Any(s)	Nom(s) original(s) a l'OSMI	Transformació aplicada	Valors exemple
		treated effectively? / If you have a mental health disorder, how often do you feel that it interferes with your work? / If you have a mental health disorder, how often do you feel that it interferes with your work *when being treated effectively?		
CATEGORIA 4 – Variables de Cultura d'Empresa (Percepció)				
facilitat_baixa	2014-2023	leave / How easy is it for you to take medical leave for a mental health condition? / How easy is it to take medical leave for a mental health condition?	Selecció primera variant per keyword 'take medical leave'. Valors NaN → 'No respon/Desconegut'.	Very Easy, Difficult, Don't Know
anonimat	2014-2023	anonymity / Is your anonymity protected if you choose to take advantage of mental health or substance abuse treatment resources? / Do you know the options for mental health care your employer provides?	Selecció per keyword 'anonymity' o 'protected'. Variable #1 en Feature Importance del model ML (22%). Valors NaN → 'No respon/Desconegut'.	Yes, No, I don't know
por_represalies	2014-2023	mental_vs_physical (2014) → 'Do you feel that your employer takes mental health as seriously as physical health?' / 'Do you think that discussing a mental health issue with your employer would have negative consequences?' / 'Would you feel comfortable discussing a mental health issue with your coworkers?'	⚠️ INVERSIÓ LÒGICA CONDICIONAL: El sentit de la pregunta canvia a partir de l'any 2017. S'aplica màscara booleana (any ≥ 2017) que inverteix Yes↔No per garantir coherència semàntica. Variable #9 en Feature Importance (2.5%).	Yes, No, Maybe
CATEGORIA 5 – Variables Organitzatives Generades Sintèticament (Mock Data)				

Variable estàndard	Any(s)	Nom(s) original(s) a l'OSMI	Transformació aplicada	Valors exemple
salari_anual	N/A – sintètica	[no existeix a l'OSMI – generada]	np.random.normal(loc=65000, scale=15000). Limitada amb .clip(25000, 150000). seed=42. Usada per calcular el KPI CPP.	52340.25, 78910.50
hores_extres_setmanals	N/A – sintètica	[no existeix a l'OSMI – generada]	np.random.poisson(lam=3). Distribució asimètrica que reflecteix entorns laborals reals. seed=42.	0, 2, 5, 12
departament	N/A – sintètica	[no existeix a l'OSMI – generada]	np.random.choice amb pesos: Backend 30%, Frontend 25%, DevOps 20%, Data/ML 12%, HR/Management 8%, QA/Testing 5%. seed=42.	Backend, DevOps
nota_rendiment	N/A – sintètica	[no existeix a l'OSMI – generada]	np.random.choice([1,2,3,4,5], p=[0.05,0.10,0.30,0.35,0.20]). Discreta 1-5, esbiaixada cap a valors alts. seed=42. Usada per calcular RFTC (R≥4).	3, 4, 5
CATEGORIA 6 – Variable de Traçabilitat Temporal				
_any_enquesta	2014-2023	[injectada automàticament per l'ETL a partir del nom del fitxer CSV]	Injectada durant la fase Extract: df['_any_enquesta'] = any. Permet l'anàlisi longitudinal. Mapejada a dim_temps → flag 'Pre-COVID' (≤2019) / 'Post-COVID' (≥2020).	2014, 2019, 2022

Figura 14. Diccionari de Dades complet: Mapeig de les 214 columnes OSMI → 17 variables estandarditzades

7.1.4. Coeficients d'Interferència per al Càlcul del KPI CPP

El Cost de Pèrdua de Productivitat (CPP) es calcula com: $CPP_i = Salari_Anual_i \times Coeficient_Interferència_i$. Els coeficients s'han definit com a regles de negoci basades en l'escala ordinal de la variable interferencia_laboral, seguint la metodologia de **Fitz-enz (2010)**:

Valor interferencia_laboral	Coefficient d'interferència	Lògica de negoci
Often / Sovint	0.20 (20% pèrdua)	Interferència severa i freqüent
Sometimes / De vegades	0.10 (10% pèrdua)	Interferència moderada
Rarely / Rarament	0.05 (5% pèrdua)	Interferència mínima
Never / Mai	0.00 (0% pèrdua)	Sense interferència
No respon/Desconegut	0.00 (0% pèrdua)	Imputació conservadora

Figura 15. Coeficients d'interferència per al càlcul del KPI CPP (Cost de Pèrdua de Productivitat)

7.1.5. Lògica de Negoci Addicional dels KPIs

Risc de Fuga de Talent Clau (RFTC)

S'identifica com a 'talent clau' tot treballador amb $\text{nota_rendiment} \geq 4$. El RFTC es calcula sobre aquest subconjunt com la proporció que presenta alhora interferència laboral ($\text{interferencia_laboral} \neq \text{'Never'}$ i $\neq \text{'No respon/Desconegut'}$). Resultat obtingut: 1.409 treballadors (sobre un total de 4.701).

Mapa de Risc per Departament (Risc_Dept)

$\text{Risc_Dept_d} = (\text{Empleats al departament d amb te_tractament} = \text{'Yes'}) / (\text{Total empleats al departament d}) \times 100$. S'aplica sobre la variable departament (sintètica) creuada amb te_tractament (clínica real). Permet generar el gràfic de barres de CPP per departament al Dashboard Power BI.

Correlació Hores Extres (Ràtio_Tractament)

$\text{Ràtio_Tractament} = P(\text{tractament} | \text{hores_extres} > 5) / P(\text{tractament} | \text{hores_extres} \leq 5)$. Calculat amb DAX sobre el model relacional. Evidencia l'impacte de la sobrecàrrega en la cerca de tractament.

7.1.6. Nota sobre la Reproductibilitat del Procés ETL

- **Llabor aleatòria:** Totes les dades sintètiques s'han generat amb `np.random.seed(42)`, garantint que qualsevol re-execució de l'script `02_etl.py` produeixi exactament el mateix dataset.
- **Idempotència:** La clàusula `ON CONFLICT DO NOTHING` a `dim_temps` prevé duplicats en re-execucions sobre la mateixa base de dades Neon.

- **Escalabilitat:** El diccionari COLUMN_MAPPING de l'script 02_etl.py pot ser ampliat per acollir futures enquestes OSMI (2024+) sense modificar la resta del pipeline.
- **Inversió lògica:** La màscara booleana (df['_any_enquesta'] >= 2017) per a la variable por_represalies ha estat validada manualment comparant les distribucions de respostes entre anys.

7.2. Codi DAX Principal

En aquest annex es detallen les mesures calculades mitjançant el llenguatge DAX (*Data Analysis Expressions*) utilitzades per a la creació dels KPIs del quadre de comandament. S'ha prioritzat l'ús de variables (VAR) per optimitzar el rendiment del motor VertiPaq i millorar la llegibilitat del codi.

7.2.1. Mètrica Base (Context de Filtre)

Aquesta és la mesura fundacional del model. En lloc de dependre de les sumes implícites de Power BI, es defineix una mesura explícita que compta les files de la taula de fets, adaptant-se dinàmicament a qualsevol filtre del *Dashboard*.

```
Total_Treballadors = COUNTROWS('fets_rendiment_benestar')
```

Taxa de Tractament (Avaluació del Context Clínic)

A partir de la mètrica base, s'ha creat un indicador relatiu per conèixer la proporció de la plantilla que actualment està rebent suport psicològic actiu.

Tècnicament, la fórmula utilitza la funció **CALCULATE** per aplicar un filtre directe i específic sobre la dimensió dim_salut_mental, aïllant únicament els empleats on l'atribut tractament_actiu és afirmatiu.

Seguidament, la funció DIVIDE calcula la proporció d'aquest subgrup respecte al total, garantint l'estabilitat del quadre de comandament en gestionar automàticament qualsevol possible divisió per zero.

```
Taxa de tractament =
VAR EmpleatsAmbTractament =
    CALCULATE(
        [Total_Treballadors],
        'dim_salut_mental'[tractament_actiu] = "Yes"
    )
RETURN
    DIVIDE(EmpleatsAmbTractament, [Total_Treballadors], 0)
```

7.2.2. Cost de Pèrdua de Productivitat (CPP) - Ús de funcions iteradores

Per calcular el CPP no es pot realitzar una suma directa. Es requereix l'ús de la funció iteradora **SUMX**, que avalua la lògica fila per fila (empleat per empleat) dins la taula de fets. S'utilitza la funció **RELATED** per navegar cap a la taula de dimensió i rescatar el nivell d'interferència, aplicant el coeficient de penalització salarial corresponent mitjançant un **SWITCH**.

```
CPP_CostProductivitat =
SUMX(
    'fets_rendiment_benestar',
    VAR Nivell_Interferencia =
        RELATED('dim_salut_mental'[interferencia_laboral])
    VAR Salari_Empleat = 'fets_rendiment_benestar'[salari_anual]

    RETURN
    SWITCH(
        Nivell_Interferencia,
        "Often", Salari_Empleat * 0.20,
        "Sometimes", Salari_Empleat * 0.10,
        "Rarely", Salari_Empleat * 0.05,
        0
    )
)
```

7.2.3. Risc de Fuga de Talent - Modificació del Context de Filtre

S'utilitza la funció **CALCULATE** per alterar el context de filtre predeterminat. Aquesta funció permet crear un subconjunt de dades on només s'avaluen els empleats que compleixen condicions d'alt rendiment (Taula de Fets) creuades amb percepcions culturals negatives (Taula de Dimensions).

```
Risc Fuga Talent =
CALCULATE(
    [Total_Treballadors],
    'fets_rendiment_benestar'[nota_rendiment] >= 4,
    'dim_cultura_empresa'[por_represalies] IN {"Yes",
    "Maybe/Not Sure"}
)
```

Dins d'aquest mateix bloc d'anàlisi de retenció, s'ha creat una mesura de normalització per expressar el pes del talent en risc sobre el total de la plantilla.

Aquesta mètrica és la que alimenta visualment el KPI principal del *Dashboard*. L'ús de la funció **DIVIDE** en lloc de l'operador de divisió convencional (/) es justifica per una qüestió de robustesa tècnica, ja que gestiona automàticament els possibles errors de divisió per zero (tornant un 0 en lloc d'un valor indefinit), garantint que el visual no presenti errors si s'apliquen filtres molt restrictius.

```
%_Fuga_Talent = DIVIDE([Risc Fuga Talent], [Total_Treballadors], 0)
```

7.2.4. Correlació d'Hores Extres (Risc Relatiu)

Aquesta mesura complexa avalua probabilísticament dues poblacions diferents (empleats amb sobrecàrrega i empleats amb jornada estàndard) dins de la mateixa fórmula, dividint-les per trobar el factor de risc relatiu.

```
Ratio_Tractament_Hores_Extres =
// 1. Probabilitat per a treballadors amb MÉS de 5 hores extremes
VAR Empleats_AltesHores =
    CALCULATE([Total_Treballadors],
    'fets_rendiment_benestar'[hores_extres_setmanals] > 5)
VAR Tractament_AltesHores =
    CALCULATE([Total_Treballadors],
    'fets_rendiment_benestar'[hores_extres_setmanals] > 5,
    'dim_salut_mental'[tractament_actiu] = "Yes")
VAR Prob_AltesHores = DIVIDE(Tractament_AltesHores,
    Empleats_AltesHores, 0)

// 2. Probabilitat per a treballadors amb 5 o MENYS hores extremes
VAR Empleats_BaixesHores =
    CALCULATE([Total_Treballadors],
    'fets_rendiment_benestar'[hores_extres_setmanals] <= 5)
VAR Tractament_BaixesHores =
```

```

    CALCULATE([Total_Treballadors],
    'fets_rendiment_benestar'[hores_extres_setmanals] <= 5,
    'dim_salut_mental'[tractament_actiu] = "Yes")
    VAR Prob_BaixesHores = DIVIDE(Tractament_BaixesHores,
    Empleats_BaixesHores, 0)

    // 3. Càlcul del Risc Relatiu (Ratio)
    RETURN
    DIVIDE(Prob_AltesHores, Prob_BaixesHores, 0)

```

Finalment, per millorar la narrativa de dades (*Data Storytelling*) al quadre de comandament, s'ha creat una mesura auxiliar que tradueix l'indicador numèric en un text dinàmic comprensible per a l'usuari final:

```

    Insight_Hores_Extres =
    VAR Risc = [Ratio_Tractament_Hores_Extres]
    VAR Percentatge = (Risc - 1) * 100
    RETURN
    "Els empleats amb sobrecàrrega tenen un " &
    FORMAT(Percentatge, "0") & "% més de risc de burnout."

```

7.3. Repositori

El repositori complet del projecte, incloent-hi scripts ETL, transformacions, models i recursos del dashboard, es troba disponible a:

[TFG benestar laboral](#)