

Disseny i implementació d'una arquitectura Business Intelligence End-to-End per a l'anàlisi i predicció del benestar laboral en el sector tecnològic

Celio Sánchez Bañuls

TFG - Business Intelligence - Aula 1

Juny 2026

Tutor de TF

Xavier Martínez Fontes

Professor/a responsable de l'assignatura

Atanasi Daradoumis Haralabus

Index

- 1. El problema: burnout al sector tech
- 2. Arquitectura End-to-End i metodologia
- 3. El repte: Schema Drift i pipeline ETL
- 4. Data Warehouse: Esquema en Estrella
- 5. Model de Machine Learning i PoC
- 6. Demo: Quadre de Comandament Power BI
- 7. Conclusions i treballs futurs

El sector tech té un problema invisible

- Alta exigència cognitiva, terminis d'entrega i síndrome de l'impostor
- Teletreball i aïllament: índexs de burnout en augment constant
- L'OMS (2022): els problemes de salut mental costen bilions d'euros anuals per pèrdua de productivitat.
- Les empreses recullen dades (enquestes OSMI) però no les converteixen en coneixement accionable.
- Aquest projecte vol omplir aquest buit: de dades clíniques a decisions estratègiques de RRHH

Objectiu: transformar dades clíniques en decisions estratègiques



- **Objectiu principal:** Dissenyar i construir un sistema BI complet que integri dades OSMI reals + variables HR sintètiques
- **OS1** Anàlisi i unificació OSMI 2014-2023 (Schema Drift).
- **OS2** Generació de dades sintètiques: salari, hores extres, rendiment.
- **OS3** Pipeline ETL automatitzat en Python.
- **OS4** Data Warehouse seguint la metodologia Kimball (Star Schema).
- **OS5** Model predictiu de Machine Learning (Random Forest)
- **OS6** Dashboard Power BI interactiu amb KPIs estratègics

Una solució completa de 5 capes

- **Capa 1 - Fonts:** 9 fitxers CSV de les enquestes OSMI (2014-2023)
- **Capa 2 - ETL:** Extracció - Neteja - Enriquiment - Càrrega (Python, Pandas, NumPy)
- **Capa 3 - Data Warehouse:** Neon PostgreSQL - Esquema en Estrella - 6 taules relacionals
- **Capa 4 - Machine Learning:** Random Forest Classifier - Scikit-Learn - 75% accuracy - Recall 82%
- **Capa 5 - Visualització:** Power BI - DAX avançat - 4 KPIs estratègics
- Metodologies: HEFESTO v2.0 (cicle de vida) + Kimball (modelatge dimensional)

Per què HEFESTO v2.0 + Kimball?

- **HEFESTO v2.0:** Marc àgil Top-Down centrat en l'usuari final (RRHH)
- 4 fases iteratives
- Descartat CRISP-DM: orientat a data mining, no a construcció de Data Warehouses
- **Kimball Star Schema:** Desnormalització intencionada - òptim per al motor VertiPaq de Power BI
- Descartat Inmon (3NF): massa complex i lent per a consultes analítiques
- L'Esquema en Estrella és el format natiu requerit per Power BI per obtenir el màxim rendiment

El repte: 9 enquestes, 214 columnes, 77.7% de valors buits

- Cada any l'OSMI reformula les preguntes - columnes noves i redundants
- Exemple: "Do you have a mental health condition?" (2014) - "Have you ever been diagnosed?" (2017)

OSMI Data Profiling Report (Global 2014-2023)

- Resultat brut: 4.701 registres - 214 columnes - 781.300 cel·les buides
- 268 alertes de qualitat detectades al Data Profiling (ydata-profiling)
- El Schema Drift feia impossible qualsevol anàlisi de BI o Machine Learning

Overview

Overview Alerts 269 Reproduction			
Dataset statistics		Variable types	
Number of variables	214	Text	159
Number of observations	4701	Numeric	19
Missing cells	781300	Unsupported	21
Missing cells (%)	77.7%	Boolean	15
Total size in memory	7.7 MiB		
Average record size in memory	1.7 KiB		

De 214 columnes a 17 variables netes: reducció del 92%

- Diccionari de mapeig semàntic en Python (COLUMN_MAPPING) amb algorisme Smart Match
- Normalització de gènere: 40+ variants de text llibre - 3 categories (RegEx)
- Inversió lògica condicional: por_represalies canvia de sentit a partir de 2017 - màscara booleana

Mètrica	Valor brut (pre-ETL)	Valor net (post-ETL)
Nombre de registres (files)	4.701	4.701 (0 eliminats)
Nombre de variables (columnes)	214	17 (reducció 92%)
Cel·les buides (NaN)	781.300 (77,7%)	<5% (imputació aplicada)
Variables de text (Text)	159	11 estandarditzades
Variables numèriques	19	6 (inclou 4 sintètiques)
Mida en memòria	7,7 MiB	<1 MiB
Alertes de qualitat detectades	268 (Schema Drift, NaN, outliers)	0 crítiques

Per què dades sintètiques? Com es generen?

- L'OSMI és clínic: no té salari, hores extres ni rendiment - sense aquests camps no es pot calcular el CPP
- **Salari anual:** Distribució Normal $N(\mu=65.000, \sigma=15.000)$ - rang [25K-150K €]
- **Hores extres:** Distribució Poisson $P(\lambda=3)$ - reflecteix l'asimetria real del món laboral
- **Departament:** `np.random.choice` amb pesos: Backend 30%, Frontend 25%, DevOps 20%...
- **Rendiment:** Escala 1-5 esbiaixada positivament (plantilla generalment competent)
- Llavor `np.random.seed(42)` - reproductibilitat científica garantida

Ecosistema de 5 mòduls Python executables en seqüència


- **00_data_profiling.py**: Anàlisi exploratòria + informe HTML - ydata-profiling
- **01_Crea_Database.py**: DDL de l'Esquema Estrella a Neon PostgreSQL - SQLAlchemy
- **02_etl.py**: Motor principal: Extract - Transform - Enrich - Load
- **03_MachineLearning.py**: Random Forest sobre dades reals OSMI - Scikit-Learn
- **04_PoC_MachineLearning.py**: Prova de Concepte amb correlació forçada - NumPy
- Disseny modular: cada script s'executa de forma independent i el sistema escala a futures enquestes OSMI

Mòdul	Funció principal	Tecnologies
00_data_profiling.py	Anàlisi Exploratòria i perfilat de dades (EDA)	pandas, ydata-profiling
01_Crea_Database.py	Definició DDL de l'Esquema en Estrella a Neon	sqlalchemy, psycopg2
02_etl.py	Motor ETL: Extract → Transform → Enrich → Load	pandas, numpy, sqlalchemy
03_MachineLearning.py	Model Random Forest sobre dades reals OSMI	scikit-learn, pandas
04_PoC_MachineLearning.py	Prova de Concepte amb correlació forçada (PoC)	scikit-learn, numpy

02_etl.py: les 4 fases del pipeline central

- **EXTRACT:** Lectura iterativa dels 9 CSV - injecció automàtica
_any_enquesta - pd.concat
- **TRANSFORM:** resolve_schema_drift - normalitzar_genere (RegEx) -
normalitzar_edat - inversió lògica 2017 - fillna(No respon)
- **ENRICH:** Injecció Mock Data NumPy - seed(42) - Normal + Poisson +
choice ponderats
- **LOAD:** Connexió SQLAlchemy - Neon - Dimensions primer (RETURNING id)
- 4.701 insercions - Exportació CSV mestre

Star Schema implementat i operatiu a Neon PostgreSQL: 6 taules relacionals



The screenshot shows the Neon PostgreSQL console interface. The left sidebar displays the project structure, including the 'production' branch and the 'neondb' database. The 'Tables' section lists the following tables:

- dim_cultura_empresa
- dim_demografia
- dim_entorn_laboral
- dim_salut_mental
- dim_temps
- fets_rendiment_benestar

The main area shows a data view for the 'fets_rendiment_benestar' table, displaying 16 rows of data. The columns are: id_salut, diagnostic_confirmat, tractament_actiu, interferencia_laboral, and fets_rendiment_benestar.

id_salut	diagnostic_confirmat	tractament_actiu	interferencia_laboral	fets_rendiment_benestar
1	Often	Yes	Often	fets_rendiment_benestar
2	Rarely	No	Rarely	fets_rendiment_benestar
3	Never	No	Never	fets_rendiment_benestar
4	Sometimes	No	Sometimes	fets_rendiment_benestar
5	Sometimes	Yes	Sometimes	fets_rendiment_benestar
6	Rarely	Yes	Rarely	fets_rendiment_benestar
7	No respon/Desconegut	No	No respon/Desconegut	fets_rendiment_benestar
8	Never	Yes	Never	fets_rendiment_benestar
9	Often	No	Often	fets_rendiment_benestar
10	No respon/Desconegut	Yes	No respon/Desconegut	fets_rendiment_benestar
11	No	Maybe/Not Sure	Not applicable to me	fets_rendiment_benestar
12	Yes	Yes	Rarely	fets_rendiment_benestar
13	Yes	Yes	Sometimes	fets_rendiment_benestar
14	Yes	No	Sometimes	fets_rendiment_benestar
15	Yes	Yes	Not applicable to me	fets_rendiment_benestar
16	Yes	Maybe/Not Sure	Rarely	fets_rendiment_benestar

Random Forest: prediu la necessitat de tractament terapèutic

- Variable objectiu: te_tractament (proxy quantificable del burnout - Reddy 2018, Katarya 2022, Memon 2023)
- 100 arbres - max_depth=10 - random_state=42 - One-Hot Encoding (36 variables d'entrada)
- Train/Test: 80/20 - 2.176 train / 544 test - exclusivament dades reals OSMI
- **Resultats:** Accuracy global: 75% - Recall (Classe 1): 82%
- Per què el Recall és crític? Un fals negatiu és un treballador que necessita ajuda i el sistema no detecta
- En prevenció de riscos laborals, minimitzar falsos negatius és prioritat absoluta

Classe	Precision	Recall	F1-Score	Support
0 – No necessita tractament	0.66	0.63	0.65	197 treballadors
1 – Necessita tractament	0.80	0.82	0.81	347 treballadors
Accuracy global	—	—	75.00%	544 treballadors
Macro avg	0.73	0.72	0.73	544 treballadors
Weighted avg	0.75	0.75	0.75	544 treballadors

Descoberta clau: l'anonimat és el factor #1 del benestar (37.3%)

Rang	Variable	Importància
1	anonimat_Yes (Percepció d'anonimat positiva)	0.2200 (22.0%)
2	anonimat_No (Absència d'anonimat)	0.1528 (15.3%)
3	edat_num (Edat numèrica de l'empleat)	0.1427 (14.3%)
4	facilitat_baixa_No respon/Desconegut	0.0534 (5.3%)
5	es_rol_tech_Yes (Rol tècnic confirmat)	0.0389 (3.9%)
6	teletreball No (Sense teletreball)	0.0334 (3.3%)
7	es_rol_tech_1.0 (Variant rol tècnic)	0.0304 (3.0%)
8	genere Masculí	0.0297 (3.0%)
9	por_represalies_No	0.0251 (2.5%)
10	genere Femení	0.0231 (2.3%)

Si els treballadors no confien que les seves dades estaran protegides, no buscaràn ajuda
Qualsevol política de benestar corporatiu que no garanteixi l'anonimat és inservible.

PoC al 99.26%: demostra que l'arquitectura funciona amb dades reals

- Escenari sandbox: correlació forçada - altes hores extres + baix rendiment = burnout operatiu
- **Resultat PoC:** Accuracy 99.26% - Recall Classe 1: 99% - F1-Score: 0.99
- **Feature Importance PoC:** Hores extres: 64.9% - Rendiment: 26.3% - variables clíniques: impacte marginal
- Interpretació correcta: NO és un model generalitzable - és una demostració tècnica controlada
- Missatge clau: una empresa només ha de substituir el fitxer de simulació pels seus registres reals de Nòmines

Classe	Precision	Recall	F1-Score	Support
0 – No burnout operatiu	0.98	0.99	0.99	197 treballadors
1 – Burnout operatiu	1.00	0.99	0.99	347 treballadors
Accuracy global	—	—	99.26%	544 treballadors


El quadre de comandament: 4 KPIs estratègics

- **Total treballadors:** 4.701 treballadors auditats al Data Warehouse
- **Massa salarial:** 306 M€ Agregació salaris sintètics de tota la plantilla
- **CPP:** 17 M€ Salari x Coeficient d'Interferència Clínica - el burnout té un cost mesurable
- **Taxa de tractament:** 37.35% Gairebé 1 de cada 3 treballadors rep suport psicològic
- **Talent crític en risc:** 29.97% Quasi 1/3 dels millors perfils opera sota fatiga severa
- Implementació amb DAX avançat: SUMX, CALCULATE, RELATED, DIVIDE, SWITCH

KPI	Valor obtingut	Descripció	Relació amb objectiu
Total treballadors	4.701	Registres nets carregats i auditats al Data Warehouse	OS3 – ETL completat
Massa Salarial total	306 milions	Agregació dels salaris sintètics generats per a tota la plantilla	OS2 – Dades sintètiques
Cost Pèrdua Productivitat (CPP)	17 milions	Estimació financera: Salari x Coeficient d'Interferència Clínica	OS1, OS4 – KPI principal
Taxa de tractament	37,35%	Proporció de la plantilla global que està rebent suport psicològic actiu.	Context clínic i base del model predictiu
Talent crític en risc	29,97%	Expressió relativa del RFTC: percentatge d'empleats d'alt valor (Rendiment ≥ 4) amb simptomatologia de fatiga o por a represàlies.	OS5 – Retenció de talent

Pestanya 1 - Global: cost per departament i risc de fuga


- **CPP per departament:** Backend 5.1M€ - Frontend 4.4M€ - els departaments sota més pressió lideren les pèrdues
- **Factor de risc:** 1.06x - els empleats amb més de 5 hores extres setmanals tenen un 6% més de risc de burnout
- Gràfic de rosca: distribució del risc de fuga de talent per mida d'empresa




Pestanya 2 - Diferències per Edat i Sexe : biaixos de gènere, mapa mundial i matriu edat/departament

- **Biaix de gènere:** Dones 47% risc (empreses 500-1000) vs homes 33% càrrega mental desigual
- Les dones presenten CPP mig superior als homes a gairebé tots els departaments
- Mapa mundial: punts calents de fatiga per país
- Matriu Edat vs Departament: micro-segmentació per intervencions psicosocials

Cost Productivitat Mig per departament i genere



% Fuga deTalent per mida de la empresa y genere



Cost Productivitat Mig per pais



edat_franja	Backend	Data/ML	DevOps	Frontend	HR/Management	QA/Testing	Total
18-24	4.164 €	2.454 €	3.477 €	3.546 €	2.789 €	3.280 €	3.487 €
25-34	3.490 €	3.565 €	3.533 €	3.785 €	3.356 €	3.652 €	3.577 €
35-44	3.441 €	3.592 €	3.860 €	3.532 €	4.005 €	3.896 €	3.625 €
45-54	3.639 €	2.531 €	4.211 €	3.086 €	4.683 €	4.215 €	3.549 €
55+	3.374 €	3.209 €	3.740 €	4.547 €	4.598 €	4.867 €	3.819 €
Desconegut	2.984 €	0 €	1.401 €	5.421 €	0 €	0 €	2.627 €
Total	3.540 €	3.339 €	3.686 €	3.639 €	3.557 €	3.754 €	3.583 €

Tots els objectius secundaris assolits

- **OS1:** 4.701 registres auditats - reducció dimensional 92%
- **OS2:** Mock Data reproducible amb lleis de distribució matemàtica
- **OS3:** 02_etl.py - resolució autònoma del Schema Drift
- **OS4:** Neon PostgreSQL - 6 taules - integritat referencial absoluta
- **OS5:** Random Forest 75% accuracy - PoC 99.26%
- **OS6:** Power BI - estimació CPP 17M€ - filtratge avançat interactiu

4 conclusions que no es poden ignorar

- **El preu del silenci:** 17M€ CPP - la salut mental és una inversió, no una despesa
- **L'anonimat com a refugi:** Sense confiança i anonimat, cap política de benestar funciona
- **L'alerta del talent:** 30% del millor talent opera sota fatiga severa - detectar-ho a temps és molt menys costós que substituir-los
- **La cultura de la sobrecàrrega:** El factor 1.06x demostra que el model de treball actual necessita revisió

Treballs futurs i tancament

- **Predicció més precisa:** XGBoost amb tuning d'hiperparàmetres - millora de l'anticipació del risc de baixa laboral
- **Streaming Data:** Integració amb Workday / BambooHR via API - KPIs en temps real
- **NLP:** Anàlisi de sentiment sobre respostes de text llibre de les enquestes
- **IA Generativa:** Copilot integrat a Power BI amb LLMs per a gestors de RRHH

“La tecnologia ha de cuidar les persones que la creen”

Moltes gràcies per la vostra atenció!